



ระบบต้นแบบทำนายความเสี่ยงภาวะทุพโภชนาการในเด็กเล็ก
โดยใช้เทคโนโลยีระบบปัญญาประดิษฐ์เชิงอธิบาย

Explainable AI system for toddler malnutrition risk prediction

จัดทำโดย

นายณัฏฐพล ทองอนันต์	รหัสนักศึกษา 65124919
นายพฤตภณ ปรีตรศิริประภา	รหัสนักศึกษา 65115800
นายสุภาวิชญ์ หนูวงศ์	รหัสนักศึกษา 65122632

อาจารย์ที่ปรึกษา

อาจารย์ ดร. มัลลิกา เกลี้ยงเกล้า

ปริญญานิพนธ์นี้เป็นส่วนหนึ่งของการศึกษา
ตามหลักสูตรปริญญาวิศวกรรมศาสตรบัณฑิต
สาขาวิศวกรรมคอมพิวเตอร์และปัญญาประดิษฐ์
สำนักวิชาวิศวกรรมศาสตร์และเทคโนโลยีมหาวิทยาลัยวลัยลักษณ์

ปีการศึกษา 2568

ระบบต้นแบบทำนายความเสี่ยงภาวะทุพโภชนาการในเด็กเล็ก
โดยใช้เทคโนโลยีระบบปัญญาประดิษฐ์เชิงอธิบาย

Explainable AI system for toddler malnutrition risk prediction

จัดทำโดย

นายณัฏฐพล ทองอนันต์	รหัสนักศึกษา 65124919
นายพฤตภณ ปรีตศิริประภา	รหัสนักศึกษา 65115800
นายสุภาวิชญ์ หนูวงศ์	รหัสนักศึกษา 65122632

อาจารย์ที่ปรึกษา

อาจารย์ ดร. มัลลิกา เกลี้ยงเกล้า

ปริญญานิพนธ์นี้เป็นส่วนหนึ่งของการศึกษา
ตามหลักสูตรปริญญาวิศวกรรมศาสตรบัณฑิต
สาขาวิศวกรรมคอมพิวเตอร์และปัญญาประดิษฐ์
สำนักวิชาวิศวกรรมศาสตร์และเทคโนโลยีมหาวิทยาลัยวลัยลักษณ์

ปีการศึกษา 2568

หน้าอนุมัติ

ชื่อโครงการ	ระบบต้นแบบทำนายความเสี่ยงภาวะทุพโภชนาการในเด็กเล็กโดยใช้เทคโนโลยีระบบปัญญาประดิษฐ์เชิงอธิบาย
ผู้เขียน	นายณัฏฐพล ทองอนันต์ นายพฤษมน ประดิษฐ์ประภา นายศุภวิชญ์ หนูวงศ์
สาขาวิชา	วิศวกรรมคอมพิวเตอร์และปัญญาประดิษฐ์

คณะกรรมการที่ปรึกษา

คณะกรรมการปริญญานิพนธ์

.....(อาจารย์ที่ปรึกษา)

.....(อาจารย์ที่ปรึกษา)

(ดร. มัลลิกา เกลี้ยงเกล้า)

(ดร. มัลลิกา เกลี้ยงเกล้า)

.....(กรรมการ)

(ผศ. ดร. พุทธิพร ธนธรรมเมธี)

.....(กรรมการ)

(ผศ. เยาวเรศ ศิริสถิตย์กุล)

ชื่อเรื่อง	ระบบต้นแบบทำนายความเสี่ยงภาวะทุพโภชนาการในเด็กเล็กโดยใช้เทคโนโลยีระบบปัญญาประดิษฐ์เชิงอธิบาย
ชื่อผู้พัฒนา	นายณัฏฐพล ทองอนันต์ นายพฤตภณ ปริตรศิริประภา นายศุภวิชญ์ หนูวงศ์
อาจารย์ที่ปรึกษา	อาจารย์ ดร.มัลลิกา เกลี้ยงเกล้า
ปริญญาและสาขาวิชา	หลักสูตรวิศวกรรมศาสตรบัณฑิต สาขาวิศวกรรมคอมพิวเตอร์และและปัญญาประดิษฐ์
ปีการศึกษา	2568

บทคัดย่อ

ภาวะทุพโภชนาการในเด็กเล็กเป็นปัญหาด้านสาธารณสุขที่เรื้อรังและมีจำนวนเพิ่มมากขึ้น และเป็นปัญหาระดับชาติในหลายประเทศทั่วโลก ซึ่งก่อให้เกิดผลเสียต่อการพัฒนาการทางกายภาพและสมอง รวมถึงเสี่ยงต่อการเกิดโรคร้ายแรงทั้งในวัยเด็กและวัยผู้ใหญ่ การประเมินความเสี่ยงจากภาวะทุพโภชนาการในปัจจุบันยังคงพึ่งพาแบบประเมินดั้งเดิมและการวินิจฉัยของบุคลากรทางการแพทย์ซึ่งมักประสบข้อจำกัดด้านทรัพยากรและเวลา

โครงการเรื่อง “ระบบต้นแบบทำนายความเสี่ยงภาวะทุพโภชนาการในเด็กเล็กโดยใช้เทคโนโลยีระบบปัญญาประดิษฐ์เชิงอธิบาย” นี้มีวัตถุประสงค์เพื่อพัฒนาโมเดลการเรียนรู้ด้วยปัญญาประดิษฐ์เชิงอธิบาย (Explainable AI: XAI) สำหรับการคาดการณ์และประเมินความเสี่ยงของภาวะทุพโภชนาการในเด็กเล็ก โดยใช้ข้อมูลทางโรงพยาบาลร่วมกับข้อมูลจากเว็บ Global Nutrition Report ที่เกี่ยวข้อง เช่น น้ำหนัก ส่วนสูง อายุ และพฤติกรรมการบริโภคอาหาร

และผลลัพธ์ที่ได้จากการพัฒนาต้นแบบการเรียนรู้ของเครื่องจากการใช้ Algorithm แบบ Classification จากการทดสอบโดยใช้โมเดล มีความแม่นยำ (Accuracy)% ผลลัพธ์ที่ได้ก็จะถูกนำไปใช้ในการจำแนกภาวะทุพโภชนาการในเด็กเล็กได้ผ่านหน้า Web Application

Title	Explainable AI system for toddler malnutrition risk prediction
Student's Name	Natchaphon Tonganant Pruettapon Paritsirapapa Supphawit Noowong
Adviser	Dr. Mallika Kliangkhiao
Degree and Program	Bachelor of Engineering Program in Computer Engineering and Artificial Intelligence
Academic Year	2024

Abstract

Malnutrition in young children is a chronic public health issue that is increasing and has become a national concern in many countries worldwide. It negatively affects physical and brain development and poses a risk for severe diseases in both childhood and adulthood. Current risk assessments for malnutrition still rely on traditional evaluation methods and diagnoses by medical personnel, which often face limitations in terms of resources and time.

The project titled "Explainable AI system for toddler malnutrition risk prediction" aims to develop an Explainable AI (XAI) model for predicting and assessing the risk of malnutrition in young children. The system utilizes hospital data combined with relevant information from the Global Nutrition Report, such as weight, height, age, and dietary behavior.

The outcome of the prototype development using machine learning with a classification algorithm, tested with the model, achieved an accuracy of%. These results will be applied to classify malnutrition status in young children through a web application interface.

กิตติกรรมประกาศ

โครงการนี้สำเร็จลงได้ด้วยความกรุณาจากอาจารย์ดร.มัลลิกา เกลี้ยงเกล้า อาจารย์ที่ปรึกษาโครงการที่ได้ให้คำแนะนำ ข้อเสนอแนะ แนวคิด ตลอดจนแก้ไขข้อบกพร่องต่าง ๆ มาโดยตลอดจนโครงการเล่มนี้เสร็จสมบูรณ์ผู้ศึกษาจึงขอขอบคุณเป็นอย่างสูง

ขอขอบคุณผู้ช่วยศาสตราจารย์ดร.พุทธิพร ธนธรรมเมธี และผู้ช่วยศาสตราจารย์เยาวเรศ ศิริสถิตย์กุลคณะกรรมการในการสอบโครงการที่ได้ให้คำแนะนำ ชี้แนะแนวทาง ในการพัฒนาโครงการให้เสร็จลง ด้วยดี

ขอบคุณโรงพยาบาลทักษิณ จังหวัดสุราษฎร์ธานี ที่ให้ข้อมูลความต้องการเกี่ยวกับการพัฒนาโมเดลและระบบ ทำให้โครงการบรรลุจุดประสงค์ และวัตถุประสงค์ที่ กำหนดไว้จนสำเร็จลงไปด้วยดี

ณัชพล ทองอนันต์

พฤตภณ ปริตรศิริประภา

ศุภวิชญ์ หนูวงศ์

สารบัญ

สารบัญตาราง

สารบัญรูปภาพ

บทที่ 1

บทนำ

1.1 ความสำคัญและที่มาของปัญหา

ปัจจุบันภาวะทุพโภชนาการ (Malnutrition) หรือสภาวะของร่างกายที่เกิดจากการได้รับอาหารที่ไม่ครบถ้วนหรือไม่เหมาะสมต่อความต้องการ เป็นปัญหาด้านสาธารณสุขที่เรื้อรังและมีจำนวนเพิ่มมากขึ้นและเป็นปัญหาระดับชาติในหลายประเทศทั่วโลก ภาวะทุพโภชนาการนับว่าเป็นภัยเงียบซึ่งเป็นหนึ่งในสาเหตุสำคัญที่นำไปสู่โรคร้ายแรงจนถึงขั้นเสียชีวิต จากรายงานขององค์กร UNICEF [1] พบว่า ทั่วโลกมีเด็กอายุน้อยกว่า 5 ปีราว 181 ล้านคนหรือร้อยละ 25 กำลังประสบปัญหาภาวะขาดสารอาหาร ซึ่งส่วนใหญ่จะได้รับประทานอาหารเพียง 0-2 หมู่ต่อวัน โดยพบเจอในเกือบ 100 ประเทศทั่วโลกและในทุกกลุ่มรายได้ ซึ่งก่อให้เกิดผลเสียต่อพัฒนาการทางกายภาพและทางสมองของเด็กโดยเฉพาะอย่างยิ่งในช่วงสองปีแรก โดยปัญหาดังกล่าวส่งผลโดยตรงให้เด็กมีภูมิคุ้มกันต้านทานโรคต่ำ เสี่ยงต่อการติดเชื้อในระบบทางเดินหายใจและระบบทางเดินอาหาร นอกจากนี้ยังทำให้ความสามารถในการเรียนรู้ลดลงและเมื่อเจริญเติบโตเป็นผู้ใหญ่ยังมีความเสี่ยงในการเป็นโรคอ้วน โรคเบาหวาน โรคหัวใจและหลอดเลือดมากขึ้น [2]

ปัจจุบันสาธารณสุขจึงได้มีนโยบายการดำเนินการป้องกันและแก้ไขปัญหาดังกล่าวผ่านการคัดกรองภาวะโภชนาการ แต่ทว่าการประเมินความเสี่ยงจากปัญหาภาวะโภชนาการยังคงพึ่งพาแบบประเมินแบบดั้งเดิมที่ออกแบบตามกลุ่มประชากรเฉพาะซึ่งต้องอาศัยการวินิจฉัยโดยบุคลากรทางการแพทย์ [3] สมาคมโภชนาการแห่งประเทศไทย [4] ได้นำเสนอคู่มือประเมินติดตามภาวะโภชนาการและพัฒนาเด็กปฐมวัย โดยมีเป้าหมายให้ผู้ปกครองและครูในโรงเรียนสามารถติดตามและประเมินการเจริญเติบโตของเด็กเล็กถึงปฐมวัยได้เบื้องต้น ซึ่งแบบคัดกรองดังกล่าวจะประเมินตามน้ำหนักและส่วนสูงของเด็ก การบริโภคอาหารของแม่และเด็กต่อวัน โดยแม้ว่าเครื่องมือดังกล่าวจะช่วยให้ผู้ปกครองสามารถประเมินรูปร่างของเด็กที่อาจเกิดจากปัญหาทุพโภชนาการ แต่ทว่าก็ยังต้องอาศัยบุคลากรผู้เชี่ยวชาญทางการแพทย์ เช่น นักโภชนาการ พยาบาล และแพทย์ในการตรวจและวินิจฉัยเพิ่มเติมเพื่อหาสาเหตุ วิธีการรักษา และวิธีป้องกัน อีกทั้งทั้งการประเมินภาวะภาวะโภชนาการต้องอาศัยการบันทึกข้อมูลอย่างต่อเนื่องทำให้เห็นว่า เป็นข้อจำกัดในเชิงปฏิบัติจากภาระงานที่สูงจากการขาดแคลนบุคลากรทางการแพทย์ ดังนั้นปัญหาดังกล่าวจึงต้องการนวัตกรรมและเทคโนโลยีเพื่อใช้สนับสนุนและแบ่งเบาภาระมนุษย์จากการศึกษาในปัจจุบันพบว่า เทคโนโลยีด้าน

วิศวกรรมคอมพิวเตอร์และปัญญาประดิษฐ์มีบทบาทสำคัญอย่างมากต่อการศึกษาวิจัยด้านการตรวจวัดและการทำนายในโรคในทางการแพทย์ Hakimah et al. [5] นำเสนองานวิจัยเพื่อทำนายภาวะแคะแกระในเด็ก โดยนำเสนอวิธีการหาคุณลักษณะสำคัญจากข้อมูลระยะปรีประวัติทางของเด็กจากศูนย์สุขภาพในประเทศอินโดนีเซียเพื่อใช้ในการทำนายโรค เช่น อายุ เพศ น้ำหนัก ส่วนสูง เส้นรอบวงแขน เป็นต้น โดยผู้วิจัยได้เสนอวิธีการทางสถิติ เช่น ANOVA, Chi-Square และ Information Gain ร่วมกับเทคโนโลยีการเรียนรู้ของเครื่อง (Machine Learning) ด้วยอัลกอริทึม Support Vector Machine แม้ว่าผลลัพธ์ที่ได้จากงานวิจัยนี้พบว่าคุณลักษณะสำคัญดังกล่าวทำให้โมเดลการเรียนรู้มีความสามารถในการทำนายภาวะแคะแกระในเด็กได้อย่างแม่นยำ (Accuracy 84.16%) แต่ทว่างานวิจัยนี้ยังไม่ได้ให้ความสำคัญในด้านการวินิจฉัยสาเหตุของโรคที่นำไปสู่การสนับสนุนการดูแลและรักษาผู้ป่วยได้ ในขณะที่ Di Martino et al. [6] ได้นำเสนอการประเมินความเสี่ยงจากภาวะทุพโภชนาโดยอาศัยกรอบแนวคิดปัญญาประดิษฐ์เชิงอธิบาย (Explainable AI: XAI) ที่บูรณาการข้อมูลทางคลินิกและข้อมูลการตรวจสอบสุขภาพร่วมกับอัลกอริทึมการเรียนรู้ของเครื่อง ได้แก่ Random Forest และ Gradient Boosting ในการจำแนกความเสี่ยงจากข้อมูลการบริโภคอาหาร และใช้ร่วมกับวิธีการอธิบายผลลัพธ์ของอัลกอริทึม SHAP (Shapley Additive Explanations) งานวิจัยดังกล่าวตั้งสมมติฐานโดยใช้ข้อมูลจากกลุ่มผู้สูงอายุในศูนย์ดูแลผู้สูงอายุในประเทศอิตาลี เช่น ข้อมูลเพศ น้ำหนัก อายุ ดัชนีมวลกาย การบริโภคอาหารประเภทต่าง ๆ ในแต่ละวัน ผลที่ได้พบว่าโมเดลการเรียนรู้ Random Forest และ Gradient Boosting มีความแม่นยำสูงในการทำนายความเสี่ยงและเมื่อประยุกต์ใช้ร่วมกับวิธีการอธิบายผลลัพธ์ของ SHAP ทำให้สามารถแสดงเหตุผลที่สนับสนุนผลการทำนายโรคของโมเดลได้อย่างชัดเจน (ความแม่นยำและ F1-score 90%) แต่ทว่างานวิจัยนี้ยังมีข้อจำกัดบางประการ คือ การวิเคราะห์ที่ต้องอาศัยข้อมูลที่หลากหลายและความซับซ้อนในการประเมินผลลัพธ์แบบส่วนบุคคล และข้อมูลที่ใช้นั้นเป็นข้อมูลเฉพาะของผู้สูงอายุ

ถึงแม้ว่าเทคโนโลยีด้านวิศวกรรมคอมพิวเตอร์และปัญญาประดิษฐ์จะถูกนำมาใช้อย่างหลากหลายเพื่อสนับสนุนทางการแพทย์ แต่เครื่องมือเหล่านี้ยังคงถูกพัฒนาในเชิงแนวคิดและไม่ได้นำเสนอในด้านการประยุกต์ใช้จริงผ่านเครื่องมือต่าง ๆ เช่น แอปพลิเคชัน โครงการนี้จึงเสนอการนำกรอบแนวคิด XAI มาใช้ในการพัฒนาระบบการคาดการณ์ความเสี่ยงของภาวะทุพโภชนาการในเด็ก ซึ่งวัตถุประสงค์หลักของโครงการนี้ คือ เพื่อพัฒนาโมเดลการเรียนรู้ตามแนวคิดปัญญาประดิษฐ์เชิงอธิบายสำหรับประเมินและทำนายความเสี่ยงของภาวะทุพโภชนาการในระยะเริ่มต้น โดยโมเดลการเรียนรู้ดังกล่าวจะถูกนำไปพัฒนาเป็นระบบต้นแบบผ่านเว็บแอปพลิเคชันสำหรับใช้งานโดยบุคลากรทางการแพทย์ โดยโครงการนี้มีเป้าหมายสำคัญเพื่อใช้ในการสนับสนุนบุคลากรทางการแพทย์ในการ

ประเมินภาวะโภชนาการของเด็กได้อย่างแม่นยำและรวดเร็ว ซึ่งจะเพิ่มประสิทธิภาพในการป้องกัน และรักษาไม่ให้เกิดภาวะทุพโภชนาการไปสู่ภาวะที่รุนแรงขึ้น

1.2 วัตถุประสงค์

1. เพื่อพัฒนาโมเดลการเรียนรู้เชิงอธิบายสำหรับประเมินและทำนายความเสี่ยงของภาวะทุพโภชนาการในระยะเริ่มต้น
2. เพื่อพัฒนาระบบต้นแบบสำหรับประเมินและทำนายความเสี่ยงของภาวะทุพโภชนาการในระยะเริ่มต้นโดยใช้เทคโนโลยีการเรียนรู้ของเครื่องและเว็บแอปพลิเคชัน

1.3 ขอบเขตของงาน

ระบบต้นแบบสำหรับประเมินและทำนายความเสี่ยงของภาวะทุพโภชนาการในระยะเริ่มต้นมี 3 กลุ่ม คือ ผู้ปกครอง บุคลากรทางการแพทย์ และผู้ดูแลระบบ มีการทำงานดังนี้

1. ผู้ปกครอง

1.1 ระบบการเข้าสู่ระบบ

ผู้ปกครองสามารถเข้าสู่ระบบผ่าน Email และ Password ของตัวเองได้ และระบบจะลิงก์เข้ากับข้อมูลประวัติการรักษา หรือ เข้าผ่านหมายเลข HN จากนั้นจะมี หมายเลข OTP เข้ามือถือของผู้ใช้เพื่อเข้าสู่ระบบ

1.2 ระบบการประเมินความเสี่ยงเบื้องต้นและดูผลลัพธ์การประเมิน

ผู้ปกครองสามารถเข้าถึงข้อมูลการประเมินความเสี่ยงทั้งหมดที่เข้ามาที่โรงพยาบาล ล่าสุดของลูก พร้อมคำแนะนำจากบุคลากรทางการแพทย์ผ่านเว็บแอปพลิเคชัน ข้อมูลที่ใช้ได้แก่

- ข้อมูลการประเมินความเสี่ยง(แต่ไม่โชว์สาเหตุ)จะบอกว่าปกติหรือควรพบแพทย์
- น้ำหนัก ส่วนสูง และระบบจะคำนวณ BMI
- โรคประจำตัว
- ปริมาณการรับประทานอาหาร เช่น กินวันละกี่มื้อ
- พฤติกรรมการรับประทานอาหาร เช่น ชอบกินอาหารจานด่วน อาหารทอด หรือไม่ชอบกินผัก
- การพักผ่อน
- การขับถ่าย

- สามารถดูได้แค่ลูกของตัวเอง

เมื่อกรอกข้อมูลแล้วระบบจะประเมินความเสี่ยงเบื้องต้นว่าควรเข้าพบแพทย์หรือไม่

1.3 ระบบแสดงคำแนะนำในการปรับเปลี่ยนการดูแลและการบริโภคอาหาร

ผู้ปกครองทุกคนสามารถกดเข้าไปดูคำแนะนำในการดูแลและบริโภคอาหารของลูก เพื่อนำไปปรับใช้ในชีวิตประจำวันของตนและลูกเพื่อป้องกันภาวะทุพโภชนาการด้วยตัวเอง

2. กลุ่มบุคลากรทางการแพทย์

2.1 ระบบการแสดงผลการประเมิน

พยาบาลสามารถเข้าถึงข้อมูลการประเมินความเสี่ยงล่าสุดของเด็ก พร้อมข้อมูลความเสี่ยงผ่านเว็บแอปพลิเคชัน ข้อมูลที่ใช้ได้แก่

- ข้อมูลการประเมินความเสี่ยง
- พยาบาลสามารถให้คำแนะนำเพิ่มเติมสำหรับหมอได้
- ผลลัพธ์การประเมินย้อนหลัง
- สามารถดูข้อมูลของผู้ป่วยทุกคนได้

3. ผู้ดูแลระบบ

3.1 ระบบคัดเลือกบุคคลที่จะเข้ามาในแผนกเด็ก

- ผู้ดูแลระบบสามารถเพิ่ม แก้ไข และลบ บุคคลที่จะเข้ามาใช้งานเว็บแอปพลิเคชันของผู้ป่วยได้ผ่านรหัส HN
- ผู้ดูแลระบบสามารถเพิ่มความสัมพันธ์บุคคลในครอบครัวได้

ขอบเขตการพัฒนาโมเดล Machine Learning

1.1 การพัฒนาโมเดล

โมเดล ML ที่ใช้สำหรับพยากรณ์ภาวะทุพโภชนาการจะถูกพัฒนา โดยใช้ข้อมูลที่เกี่ยวข้อง เช่น น้ำหนัก ส่วนสูง อายุ ประวัติการบริโภคอาหาร ข้อมูลเหล่านี้จะถูกนำเข้าสู่มอเดลเพื่อพยากรณ์ความเสี่ยง โดยใช้ Random Forest, SVM และ Artificial Neural Network โดยการเลือกใช้จะขึ้นอยู่กับผลลัพธ์คือ Accuracy, Precision, Recall, F1-score ของแต่ละโมเดลเพื่อหาโมเดลที่ดีที่สุด

1.2 Explainable AI (XAI)

การใช้เทคนิค SHAP (Shapley Additive Explanations) เพื่ออธิบายผลลัพธ์ฟิเจอร์ของโมเดล Machine Learning ว่าฟิเจอร์ไหนมีผลมากที่สุดที่ทำให้เกิดความเสี่ยงเพื่อให้แพทย์สามารถอธิบายได้ว่าเป็นเพราะอะไร เช่น ผลแสดงออกมาว่าฟิเจอร์อาหารต่อมามีผลมากที่สุด จากนั้นแพทย์ก็จะทำการวิเคราะห์เพื่อหาสาเหตุและวิธีการแก้ไขต่อไป

1.3 การบูรณาการกับเว็บแอปพลิเคชัน

โมเดล Machine Learning จะถูกติดตั้งไว้ในส่วนของ Backend ของระบบ โดยการใช้ภาษา Python ร่วมกับเฟรมเวิร์กเช่น FastAPI เพื่อเชื่อมต่อกับเว็บแอปพลิเคชันและทำให้กรอกข้อมูลได้ และเก็บข้อมูลโมเดลไว้ในรูปแบบ API ผู้ใช้สามารถกรอกข้อมูล และแสดงผลลัพธ์จากโมเดลได้แบบเรียลไทม์

1.4 ประโยชน์ที่คาดว่าจะได้รับ

โครงการนี้มีเป้าหมายเพื่อสนับสนุนการให้ผู้ปกครองและบุคลากรทางการแพทย์สามารถประเมินและติดตามความเสี่ยงภาวะทุพโภชนาการในเด็กเล็กในระยะเริ่มต้นได้อย่างแม่นยำและรวดเร็ว ลดภาระงานในการประเมินภาวะโภชนาการ เพิ่มโอกาสในการป้องกันและรักษาภาวะทุพโภชนาการตั้งแต่วะเริ่มต้น รวมถึงส่งเสริมการนำเทคโนโลยีปัญญาประดิษฐ์มาใช้ในการด้านสาธารณสุขอย่างมีประสิทธิภาพ

1.5 ผลที่คาดว่าจะได้รับเมื่อเสร็จสิ้นโครงการ

- 1) ได้โมเดลการเรียนรู้เชิงอธิบายสำหรับประเมินและทำนายความเสี่ยงของภาวะทุพโภชนาการในระยะเริ่มต้น
- 2) ได้ระบบต้นแบบสำหรับประเมินและทำนายความเสี่ยงของภาวะทุพโภชนาการในระยะเริ่มต้นโดยใช้เทคโนโลยีการเรียนรู้ของเครื่องและเว็บแอปพลิเคชัน

1.6 ขั้นตอนการดำเนินงาน

ระยะเวลาดำเนินงาน 11 เดือน ตั้งแต่เดือน ตุลาคม พ.ศ. 2567 ถึงเดือน สิงหาคม พ.ศ. 2568

ตารางที่ 1 รายละเอียดขั้นตอนการดำเนินงาน

แผนการดำเนินงาน	ตุลาคม 2024				พฤศจิกายน 2024				ธันวาคม 2024				มกราคม 2025				กุมภาพันธ์ 2025				มีนาคม 2025				เมษายน 2025				พฤษภาคม 2025				มิถุนายน 2025				กรกฎาคม 2025				สิงหาคม 2025	
	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2								
ศึกษาปัญหาและระบบ																																										
เขียนข้อเสนอโครงการ																																										
สอบข้อเสนอโครงการ					^																																					
รวบรวมและวิเคราะห์ข้อมูล																																										
ทดสอบเครื่องมือและอัลกอริทึมสำหรับพัฒนาโมเดล																																										
พัฒนาโมเดลสำหรับประมวลผล																																										
สอบความก้าวหน้าโครงการ 1													^																													
พัฒนาระบบส่วนหน้าและส่วนหลัง																																										
ทดสอบและประเมินผล																																										
สอบกลางภาคโครงการ 2																					^1																					
สรุปผลโครงการ																																										
สอบโครงการ 2																																		^2								
สอบโครงการ 2 ภาคโปสเตอร์																																										

หมายเหตุ

^

^

หมายถึง ระยะเวลาดำเนินงาน
หมายถึง สอบข้อเสนอโครงการ
หมายถึง สอบความก้าวหน้าโครงการ

$\wedge 1$	หมายถึง ช่วงเวลาสอบของโครงการงาน 1
$\wedge 2$	หมายถึง ช่วงเวลาสอบของโครงการงาน 2

1.7 อุปกรณ์ที่ใช้ในการพัฒนางาน

การพัฒนาระบบ ผู้พัฒนาได้เลือกใช้เครื่องมือที่หลากหลาย เพื่อการใช้งานที่หลากหลาย ครบถ้วนตามความต้องการซึ่งมีทั้งซอฟต์แวร์และฮาร์ดแวร์ดังนี้

1) ด้านซอฟต์แวร์ (Software)

ตารางที่ 1.2 รายละเอียดอุปกรณ์ซอฟต์แวร์ (Software) ที่ใช้ในการพัฒนา

ชุดอุปกรณ์/ชุดคำสั่ง	คำอธิบาย
ระบบปฏิบัติการ Windows 11	Windows 11: Windows 11 เป็นระบบปฏิบัติการ ใหม่ล่าสุดจาก Microsoft ที่มาพร้อมกับ อินเทอร์เน็ตใหม่ ที่ทันสมัยขึ้น พร้อมคุณสมบัติ การทำงานแบบไฮบริด ช่วยเพิ่มประสิทธิภาพการ ทำงานระยะไกล ปกป้องได้ทั้ง ฮาร์ดแวร์ ซอฟต์แวร์ ไปจนถึงระบบไคลเอนต์
ฐานข้อมูล SQL <ul style="list-style-type: none">• Firebase	Firebase: Firebase คือชุดเครื่องมือและบริการที่ครอบคลุมซึ่งนำเสนอเป็นแพลตฟอร์ม Backend-as-a-Service (BaaS) ช่วยให้นักพัฒนาร่าง เปิดใช้ และขยายทั้งแอปพลิเคชันมือถือและเว็บได้อย่างง่ายดาย มีฐานข้อมูลเรียลไทม์ การพิสูจน์ตัวตน พื้นที่เก็บข้อมูล โฮสต์ตั้ง และคุณลักษณะอื่นๆ อีกมากมาย และจัดการทั้งหมดได้จากแพลตฟอร์มเดียว
ซอฟต์แวร์สำหรับการพัฒนาระบบ <ul style="list-style-type: none">• Visual Studio Code• scikit-learn, pandas• Shap• FastAPI• HTML,CSS• Github• React Framework	Visual Studio Code:คือ โปรแกรม Code Editor ของ Microsoft ที่ใช้สำหรับเขียน แก้ไขและตรวจสอบความ ผิดปกติของโค้ด คุณสมบัติของโปรแกรมมีลักษณะเบา มีประสิทธิภาพสูง มีส่วนขยาย (Extension) เพื่อเพิ่มขีดความสามารถและสามารถเขียนโค้ดได้หลากหลายภาษา scikit-learn, pandas: ไลบรารี (library) สำหรับ การทำงานกับการเรียนรู้ machine learning ด้วยภาษา Python เป็นหนึ่งในไลบรารีที่ "ได้รับความนิยม สูงสุด" สำหรับการทำงานทางด้านนี้และมี ความหลากหลายของ อัลกอริทึม Shap:เป็นเทคนิค XAI (Explainable AI) ที่ใช้แนวคิดจาก ทฤษฎีเกมในการวิเคราะห์และอธิบายผลลัพธ์ของโมเดล AI

ชุดอุปกรณ์/ชุดคำสั่ง	คำอธิบาย
	<p>โดยให้คะแนนความสำคัญของแต่ละฟีเจอร์ในโมเดล ซึ่งช่วยให้เข้าใจว่าฟีเจอร์ใดมีผลต่อการตัดสินใจของโมเดลอย่างไร โดยยึดหลักความยุติธรรมในการกระจายค่าความสำคัญระหว่างฟีเจอร์ต่าง ๆ</p> <p>FastAPI: framework สำหรับการสร้าง API (Application Programming Interface) ด้วยภาษา Python ที่ได้รับความนิยมเนื่องจากความเร็วและ ประสิทธิภาพที่สูง</p> <p>HTML, CSS: HTML เป็นภาษาที่ใช้ในการสร้างและกำหนดโครงสร้างของหน้าเว็บไซต์ CSS เป็นภาษา ที่ใช้ในการกำหนดรูปแบบและการจัดหน้าตาของ เว็บไซต์ เมื่อ HTML ใช้สำหรับกำหนดโครงสร้าง</p> <p>Github: เป็นแพลตฟอร์มคลาวด์ที่ให้บริการ นวัตกรรมด้านคลาวด์และบริการความรู้ด้าน เทคโนโลยีของ Google สำหรับธุรกิจและ นักพัฒนา</p> <p>React: เป็นไลบรารี JavaScript ที่พัฒนาโดย Facebook เพื่อช่วยสร้าง User Interface (UI) ที่มีประสิทธิภาพ โดย React มุ่งเน้นการสร้าง Component ซึ่งเป็นส่วนประกอบของ UI ที่สามารถใช้ซ้ำได้ และแต่ละ Component สามารถเก็บสถานะ (state) และเมทอด (methods) ต่าง ๆ เพื่อการจัดการกับข้อมูลและการแสดงผล</p>
<p>ซอฟต์แวร์สำหรับการจัดการเอกสาร</p> <ul style="list-style-type: none"> • Microsoft Office • Google Document 	<p>Microsoft Office: เป็นชุดโปรแกรมสำนักงานที่ ถูกพัฒนาและจัดจำหน่ายโดยบริษัท Microsoft ชุดโปรแกรมนี้ประกอบด้วยแอปพลิเคชันต่าง ๆ 8 ที่ให้บริการในหลายด้านของการทำงาน, รวมถึง การจัดการเอกสาร</p> <p>Google Document: เป็นบริการออนไลน์ที่ให้คุณสามารถจัดการเอกสารได้บนเว็บไซต์ เพียงแค่คุณมีอีเมลของ Gmail และเชื่อมต่ออินเทอร์เน็ต</p>
<p>การสนับสนุนการทำงาน</p> <ul style="list-style-type: none"> • Discord 	<p>Discord: แพลตฟอร์มการสื่อสารยอดนิยมที่ออกแบบมาสำหรับการสื่อสาร และส่งเสริมการมีปฏิสัมพันธ์ระหว่าง</p>

ชุดอุปกรณ์/ชุดคำสั่ง	คำอธิบาย
	ผู้ใช้ ประกอบไปด้วยการส่งข้อความโต้ตอบแบบเรียลไทม์ แช็ตด้วยเสียง และวิดีโอแช็ตไว้ในช่องทางเดียว

2) ด้านฮาร์ดแวร์ (Hardware)

ตารางที่ 1.3 รายละเอียดอุปกรณ์ฮาร์ดแวร์ (Hardware) ที่ใช้ในการพัฒนา

ชุดอุปกรณ์/ชุดคำสั่ง	คำอธิบาย
<p>เครื่องคอมพิวเตอร์สำหรับการพัฒนา</p> <ul style="list-style-type: none"> ASUS รุ่น TUF Gaming F15 MSI รุ่น Thin 15 B13VE MSI รุ่น GF36 Thin 10UC 	<p>ASUS รุ่น TUF Gaming F15:</p> <ul style="list-style-type: none"> - CPU : Intel Core i5 11400H (2.69GHz up to 2.70 GHz) - GPU : nVidia GeForce RTX 3050 Ti Laptop - RAM : 16GB - OS : Windows 11 Home 64bit <p>MSI รุ่น Thin 15 B13VE:</p> <ul style="list-style-type: none"> - CPU :Intel Core i5-13420H 2.10 GHz - GPU : NVIDIA GeForce RTX 4050 Laptop GPU (6GB GDDR6) - RAM : 16 GB DDR4 - OS : Windows 11 Home 64bit <p>MSI รุ่น GF36 Thin 10UC:</p> <ul style="list-style-type: none"> - CPU :Intel Core i5-1050H CPU @ 2.50 GHz - GPU : NVIDIA GeForce RTX 3050 Laptop GPU (6GB) - RAM : 24 GB SSD - OS : Windows 11 Home 64bit

บทที่ 2

ทฤษฎีและเทคโนโลยีที่เกี่ยวข้อง

2.1 ทฤษฎีที่เกี่ยวข้อง

2.1.1 ภาวะทุพโภชนาการ [2] คือ ภาวะที่ร่างกายได้รับสารอาหารผิดเพี้ยนไปจากปกติ อาจเกิดจากได้รับสารอาหารน้อยกว่าปกติหรือเหตุทุติยภูมิ คือ ความบกพร่องทางร่างกาย ภาวะทุพโภชนาการแบ่งเป็น 2 ประเภท คือ ภาวะโภชนาการต่ำ และ ภาวะโภชนาการเกิน โดยภาวะโภชนาการต่ำ คือ สภาวะของร่างกายที่เกิดจากการได้รับอาหารไม่เพียงพอ หรือได้รับสารอาหารไม่ครบ หรือมีปริมาณต่ำกว่าที่ร่างกายต้องการทำให้เกิดโรคลักปิดลักเปิด และ ภาวะโภชนาการเกิน คือ สภาวะของร่างกายที่ได้รับอาหารหรือสารอาหารบางอย่างเกินกว่าที่ร่างกายต้องการ ทำให้เกิดการสะสมพลังงานหรือสารอาหารบางอย่างไว้จนเกิดโทษแก่ร่างกาย

ปัจจัยที่ส่งผลภาวะทุพโภชนาการแบบต่ำ [7] มีดังนี้

1. แม่มีภาวะเตี้ย (ขาดอาหารเรื้อรัง) ในวัยเด็ก
2. แม่มีน้ำหนักตัวน้อยก่อนตั้งครรภ์
3. เด็กมีน้ำหนักแรกเกิดน้อยกว่า 2,500 กรัม
4. ครอบครัวเด็กมีฐานะยากจน
5. การเจ็บป่วยด้วยโรคติดเชื้อของทารกและเด็ก ทำให้เด็กได้รับสารอาหารเข้าสู่ร่างกายได้น้อย เช่น เป็นหวัด ปอดบวม ท้องร่วง เป็นต้น
6. ระดับการศึกษาของพ่อแม่ ผู้ปกครองไม่ดี ทำให้การขาดความรู้ที่รู้ ที่ถูกต้องในการเลี้ยงดู และในการจัดอาหารให้แก่ทารกและเด็ก และมีความเชื่อบางอย่างที่ห้ามกินอาหารบางชนิด
7. แม่มีลูกมากและระยะห่างของการมีลูกสั้น
8. การเข้าถึงระบบบริการสาธารณสุขไม่ดี

ปัจจัยที่ส่งผลภาวะทุพโภชนาการแบบเกิน [7] มีดังนี้

1. กรรมพันธุ์
2. น้ำหนักแรกเกิดมาก
3. กินจุบจิบ
4. กินข้าว-แป้งมาก

5. กินอาหารที่มีไขมันมาก หรือของทอดบ่อย ๆ
6. กินอาหาร ขนมห หรือเครื่องดื่มที่มีรสหวานเป็นประจำ
7. เคลื่อนไหวร่างกายน้อย

โรคที่เกิดจากภาวะทุพโภชนาการ เช่น โรคเกาต์ โรคเลือดจาง โรคเหน็บชา โรคปากนก กระจอก โรคคอ พอก โรค ตาฟาง โรคอ้วน โรคความดันโลหิตสูง โรคเบาหวาน โรคไต โรคขาดโปรตีน โรคนิ้ว โรคลักปิดลักเปิด โรคหัวใจขาด เลือด โรคกระดูกอ่อน [2] โดยภาวะทุพโภชนาการในเด็กเล็ก มีทั้งหมด 5 ระดับ [8] ดังตารางที่ 2.1

ตารางที่ 2.1 ระดับภาวะทุพโภชนาการ

ระดับ	ความหมาย	ผลกระทบ	การฟื้นตัว
ปกติ	เด็กที่มีค่าน้ำหนักต่อส่วนสูง น้ำหนักตามอายุ และ ส่วนสูงตามอายุ มีค่าเบี่ยงเบนมาตรฐานอยู่ในช่วง -2 ถึง +2 คืออยู่ในเกณฑ์ปกติ	ไม่มีผลกระทบ เพราะสุขภาพโดยรวมดี การเจริญเติบโตเป็นไปตามปกติ	ไม่มีการฟื้นตัวที่จำเป็น เพราะเด็กมีสุขภาพที่ดีอยู่แล้ว
น้ำหนักเกิน	เด็กที่มีค่าน้ำหนักต่อส่วนสูงสูงกว่าค่าเบี่ยงเบนมาตรฐานสองค่า (+2 s.d.)	เสี่ยงต่อโรคเรื้อรัง เช่น ความดันโลหิตสูง และ ปัญหาการเผาผลาญ	ลดปริมาณอาหารที่มีพลังงานสูง เพิ่มการออกกำลังกาย
น้ำหนักน้อยเกินไป	เด็กที่มีค่าน้ำหนักตามอายุต่ำกว่าค่าเบี่ยงเบนมาตรฐานสองค่า (-2 s.d.)	ส่งผลต่อการเจริญเติบโตและภูมิคุ้มกันอ่อนแอ	เพิ่มอาหารที่มีคุณค่าทางโภชนาการ
แคระแกร็น	เด็กที่มีค่าส่วนสูงตามอายุต่ำกว่าค่าเบี่ยงเบนมาตรฐานสองค่า (-2 s.d.)	พัฒนาการล่าช้า ทั้งทางร่างกายและสมอง	ต้องได้รับการเสริมโภชนาการ

ระดับ	ความหมาย	ผลกระทบ	การฟื้นฟู
ภาวะทุพโภชนาการ เฉียบพลันรุนแรง (SAM)	เด็กที่มีค่าน้ำหนักต่อ ส่วนสูงต่ำกว่าค่า เบี่ยงเบนมาตรฐาน สามค่า (-3 s.d.)	น้ำหนักลดอย่างมาก ระบบ ภูมิคุ้มกัน อ่อนแอ ระบบทางเดิน อาหารบกพร่อง อัตรา การเต้นของหัวใจช้า ลง ความดันโลหิตต่ำ พัฒนาของสมองช้าลง ภาวะโลหิตจาง เกิด ภาวะขาดน้ำ และ ความไม่สมดุลของ เกลือแร่ ทำให้เป็น อันตรายถึงชีวิต	ต้องการการรักษาทาง การแพทย์ทันที และ ต้องใช้อาหารเสริม พลังงานและ สารอาหารที่เหมาะสม เพื่อฟื้นฟูสภาพ ร่างกาย

2) การเรียนรู้ของเครื่อง (Machine Learning) เป็นสาขาวิชาที่ช่วยให้คอมพิวเตอร์สามารถเรียนรู้ได้โดยไม่ต้องตั้งโปรแกรมไว้อย่างชัดเจน หรือ การทำให้ระบบคอมพิวเตอร์สามารถเรียนรู้ได้ด้วยตนเองโดยใช้ข้อมูล XAI คือ แนวคิดและชุดเทคนิคที่ออกแบบมาเพื่อทำให้โมเดลการเรียนรู้ของเครื่องที่มีความซับซ้อนสามารถทำให้มนุษย์สามารถเข้าใจเหตุผลเบื้องหลังผลลัพธ์ของอัลกอริทึมได้ [9] โดยทั่วไปแล้วอัลกอริทึมของเรียนรู้ของเครื่อง (Machine Learning) มักทำงานเป็นกล่องดำ(Black Box) ที่รับอินพุตและเอาต์พุตโดยไม่มีทางเข้าใจการทำงานภายในของมันได้

2.1.2 Algorithm สำหรับการจำแนกกลุ่มข้อมูล (Classification Model) แบ่งเป็น 5 ประเภท

1. Neural Networks

1) Multi-layer Perceptron (MLP)

Multi-layer Perceptron Neural Network หรือโครงข่ายประสาทเทียมแบบย้อนกลับ (Feed-forward Backpropagation Neural Network) โดยมีโครงสร้างพื้นฐานประกอบด้วย 3 ส่วน ได้แก่ Input layer, Hidden layer และ Output layer เป็น Perceptron ที่มีมากกว่า 1 ชั้น โดยแต่ละชั้นจะมีการรับค่าและคำนวณค่าผลรวมของข้อมูลนำเข้ากับน้ำหนักแต่ละจุดเชื่อมโยงเพื่อส่งไปยังโหนดเชื่อมต่อถัดไปจนถึงโหนด Output

และมีการย้อนกลับไปยังโหนด Input เพื่อปรับค่าน้ำหนักในแต่ละจุดเชื่อมโดยดูจาก Error/Cost ที่เกิดขึ้นในแต่ละ Neurons

2. Distance-Based Models

1) K-Nearest Neighbor (KNN)

เป็นวิธีการแบ่งหมวดหมู่ข้อมูลสำหรับใช้จัดหมวดหมู่ข้อมูล (Classification) โดยหลักการคือ เปรียบเทียบข้อมูลที่สนใจกับข้อมูลอื่นว่ามีความใกล้เคียงข้อมูลใดมากที่สุด ก็จะจัดอยู่ในกลุ่มข้อมูลนั้น โดยการกำหนดค่า k คือข้อมูลบางจำนวนที่ใช้ในการหาระยะห่างกับข้อมูลที่สนใจและจัดกลุ่มข้อมูลให้กับข้อมูลที่สนใจ จึงได้มีการนำทฤษฎีบทพิทาโกรัสมาใช้ คือ กำลังสอง ของด้านตรงข้ามมุมฉาก = ผลรวมของกำลังสองของด้านประชิด และได้ประยุกต์ใช้กับการจัดหมวดหมู่โดยสูตรการคำนวณมีดังนี้

$$dist = \sqrt{\sum_{k=1}^n (p_k - q_k)^2}$$

p คือค่าของชุดข้อมูลที่ต้องการจำแนก

q คือค่าของชุดข้อมูลเพื่อนบ้านที่นำมาพิจารณา

2) Support Vector Machine (SVM)

เป็นหนึ่งในโมเดล Machine Learning ที่ใช้ในการจำแนกข้อมูล หรือแบ่งกลุ่มชุดข้อมูล โดยจะสร้างเส้นตรงที่ใช้แบ่งกลุ่มชุดข้อมูลเพื่อหาเส้นตรงที่แบ่งกลุ่มชุดข้อมูลได้ดีที่สุด เส้นตรงนั้น เรียกว่า Hyperplane โดยเลือกจากเส้นที่มีระยะขอบของเส้นระหว่างกลุ่มของข้อมูลมากที่สุด ทั้งนี้ข้อมูลบางชุดไม่สามารถแบ่งกลุ่มได้ด้วยเส้นตรง (Linear) จึงได้มีวิธีการ Kernels ที่เป็น Non-Linear เข้ามาแก้ไขปัญหาที่เกิดขึ้น หลักการทำงานของ Kernels คือ สร้างมิติของชุดข้อมูล จาก 2D เป็น 3D แล้วลากเส้นตรงผ่านก็จะสามารถแบ่งกลุ่มข้อมูลได้อีกทั้ง Kernels แต่ละแบบ ก็จะมีสมการเป็นรูปแบบที่ไม่เหมือนกันทำให้สามารถเลือกได้ให้เหมาะสมกับข้อมูลแต่ละประเภท ตัวอย่าง Kernels ที่เป็นที่นิยมเช่น Gaussian RBF โดยมีรูปสมการคือ

$$\text{Gaussian RBF: } K(a, b) = e^{(-\gamma \|a-b\|^2)}$$

3. Logical Models

1) Decision Tree

Decision Tree หรือต้นไม้ตัดสินใจเป็น Classification Model ที่ใช้กระบวนการ RuleBased คือเป็นการสร้างกฎ If-Else ขึ้นมา เป็นวิธีการแยกข้อมูลถ้าข้อมูลเข้ากฎที่ตั้งขึ้น ก็จะแยก ไปอยู่กลุ่มหนึ่ง ถ้าไม่เข้ากฎก็จะแยกไปอยู่อีกกลุ่มหนึ่ง โดยมีสูตรการคำนวณดังนี้

$$\text{Gini Impurity} = \sum_{i=1}^C p(i) * (1 - p(i))$$

2) Random Forest

เป็นอัลกอริทึมในกลุ่ม Machine Learning ที่ได้รับการพัฒนาโดย Leo Breiman และ Adele Cutler ซึ่งเป็นที่นิยมใช้งานอย่างแพร่หลาย เนื่องจากความสามารถในการผสมผสานผลลัพธ์จากต้นไม้ตัดสินใจ (Decision Trees) หลายต้นเพื่อให้ได้คำตอบเพียงหนึ่งเดียว ความง่ายในการใช้งานและความยืดหยุ่นของมันทำให้อัลกอริทึมนี้ได้รับความนิยม โดยสามารถจัดการได้ทั้งปัญหา Classification และ Regression ได้อย่างมีประสิทธิภาพ โดยสูตรที่ใช้ในการตัดสินใจ มีดังนี้

สูตรที่ 1

$$\text{Gini} = 1 - \sum_{i=1}^C (p_i)^2$$

สูตรที่ 2

$$\text{Entropy} = \sum_{i=1}^C -p_i * \log_2(p_i)$$

3) ExtraTrees

เป็นอัลกอริทึม Ensemble Learning ที่ใช้ต้นไม้ตัดสินใจหลายต้น พร้อมการสุ่มค่า Threshold เพื่อเพิ่มความเร็ว ลดความแปรปรวน และเหมาะสำหรับงาน Classification และ Regression ที่ต้องการความแม่นยำและความเสถียรสูง

4. Probabilistic Models

1) Naïve Bayes

การจำแนกข้อมูลด้วยวิธีการเบย์เซียนจะเป็นการสร้างตัวจำแนกข้อมูลด้วยการ ประยุกต์ใช้ ค่าทางสถิติ เป็นหนึ่งใน Classification Model ใช้ในการแบ่งกลุ่มหรือหาเหตุการณ์ที่ จะเกิดขึ้นโดย

การอิงทฤษฎีความน่าจะเป็นของ Bayes หรือ Bayesian ซึ่ง Target ของโมเดลจะ มีความคล้ายคลึงกับ Logistic Regression ว่าจะเกิดเหตุการณ์นั้นหรือไม่โดยจะเพิ่มโอกาสใน การเกิดเหตุการณ์เข้าไปด้วย โดยมักจะใช้ในการวิเคราะห์ข้อมูลที่มีความต่อเนื่องของเหตุการณ์ (Dependent Event) ซึ่งจำเป็นจะต้องอาศัยการคำนวณผ่านสูตรดังนี้

$$P(A|B) = \frac{P(B|A) P(A)}{P(B)}$$

$P(A|B)$ คือความน่าจะเป็นในการเกิดเหตุการณ์A โดยมีB เป็น Condition

$P(B|A)$ คือความน่าจะเป็นในการเกิดเหตุการณ์B โดยมีA เป็น Condition

$P(A)$ คือโอกาสในการเกิดเหตุการณ์A จากเหตุการณ์ทั้งหมด

$P(B)$ คือโอกาสในการเกิดเหตุการณ์B จากเหตุการณ์ทั้งหมด

2) Logistic Regression

Logistic Regression เป็นเทคนิคในการวิเคราะห์ข้อมูลเพื่อพยากรณ์ความน่าจะเป็นใน การเกิดเหตุการณ์หรือไม่เกิดเหตุการณ์นั้น โดยทฤษฎีความน่าจะเป็นจะแบ่งออกเป็นทวินาม หรือเรียกว่า Binomial Logistic Regression แต่ถ้าตัวแปรตามเป็นพหุนามจะเรียกว่า Multinomial Logistic Regression โดยสูตรการคำนวณพื้นฐานเป็นดังนี้

$$\frac{p(X)}{1 - p(X)} = \exp(\beta_0 + \beta_1 X)$$

$p(X)$ คือความน่าจะเป็นในการเกิดเหตุการณ์ X

$1-p(X)$ คือความน่าจะเป็นที่จะไม่เกิดเหตุการณ์ X

\exp คือการหา Exponential ของสมการ

β_0 คือค่า Intercept หรือค่าคงที่ซึ่งจะเป็นค่าที่ส่งผลต่อสมการ Regression

β_1 คือค่า Parameter หรือค่าสัมประสิทธิ์ของตัวแปรอิสระ

X คือตัวแปรอิสระ

5. Ensemble Models

1) GradientBoosting

เป็นอัลกอริทึมการเรียนรู้ของเครื่องในกลุ่ม Ensemble Learning ที่สร้างโมเดลที่ดีโดยรวมผลลัพธ์จากโมเดลที่ผิดพลาดหลาย ๆ โมเดล (เช่น decision trees) เข้าด้วยกัน โดยในแต่ละขั้นตอนโมเดลใหม่จะถูกฝึกเพื่อแก้ไขข้อผิดพลาดของโมเดลก่อนหน้า ทำให้สามารถจัดการกับปัญหาการจำแนกประเภทและการถดถอยได้อย่างมีประสิทธิภาพ

2) AdaBoostClassifier (Adaptive Boosting)

เป็นอัลกอริทึมในกลุ่ม Ensemble Learning ที่ออกแบบมาเพื่อเพิ่มความแม่นยำของการจำแนกประเภทโดยการรวม Weak Learners (โมเดลที่มีประสิทธิภาพต่ำ เช่น Decision Stump) หลาย ๆ ตัวเข้าด้วยกันเพื่อสร้าง Strong Learner ที่มีประสิทธิภาพสูงขึ้น

3) XGBoost (eXtreme Gradient Boosting)

คือไลบรารีสำหรับการเพิ่มประสิทธิภาพของ Gradient Boosting ที่ถูกพัฒนาให้มีประสิทธิภาพสูง ยืดหยุ่น และพกพาได้ง่าย โดยเป็นการนำอัลกอริทึมการเรียนรู้ของเครื่อง (Machine Learning) ภายใต้กรอบแนวคิด Gradient Boosting มาประยุกต์ใช้งาน XGBoost สนับสนุนการสร้างแบบจำลองต้นไม้แบบขนาน (Parallel Tree Boosting หรือที่รู้จักกันในชื่อ GBDT และ GBM) ซึ่งช่วยแก้ปัญหาด้านข้อมูลศาสตร์ได้อย่างรวดเร็วและแม่นยำ โค้ดเดียวกันนี้ยังสามารถทำงานบนสภาพแวดล้อมการกระจายงานหลัก (Hadoop, SGE, MPI) และสามารถแก้ปัญหาที่มีตัวอย่างข้อมูลเกินพันล้านตัวอย่างได้อีกด้วย

2.1.2 Algorithm เชิงอธิบาย (Explanation AI)

อัลกอริทึมเชิงอธิบาย คือ วิธีการหรือเทคนิคที่ออกแบบมาเพื่อให้การทำงานและการตัดสินใจของแบบจำลองการเรียนรู้ของเครื่องสามารถเข้าใจและตรวจสอบได้ ซึ่งเป็นส่วนสำคัญของการพัฒนา Explainable AI (XAI) โดยอัลกอริทึมเหล่านี้มุ่งเน้นการสร้างคำอธิบายที่มีความหมายและเข้าใจง่ายสำหรับการตัดสินใจของแบบจำลอง การวิเคราะห์ด้วย Explanation AI สามารถทำได้ 2 ระดับได้แก่


ระดับภาพรวม (Global Explanation): เป็นการวิเคราะห์โดยใช้ข้อมูลทั้ง Dataset เพื่อหาฟีเจอร์ที่ส่งผลต่อแต่ละ class

ระดับเฉพาะกรณี (Local Explanation): เป็นการวิเคราะห์เฉพาะข้อมูล 1 แถว จาก Dataset ทั้งหมด เช่น ในกรณีที่มีข้อมูลของคน 100 คน การวิเคราะห์ระดับเฉพาะกรณีจะดูข้อมูลของคนเพียงคนเดียวและวิเคราะห์ว่าฟีเจอร์ใดที่ส่งผลมากที่สุดต่อคน ๆ นั้น

อัลกอริทึมเชิงอธิบายมีรายละเอียด ดังนี้

1) SHAP (SHapley Additive exPlanations)

เป็นหนึ่งในเทคนิคของ XAI (Explainable AI) ที่ใช้ในการอธิบายการทำงานของโมเดล Machine Learning ที่มีความซับซ้อน โดยเทคนิคนี้อ้างอิงจากหลักการของ Shapley value ซึ่งเป็นการคำนวณภายใต้ทฤษฎีเกมแบบร่วมมือ (coalitional game theory) ในการทำงานของ SHAP จะมองค่าของฟีเจอร์แต่ละตัวเป็น "ผู้เล่น" (player) ของเกม และผลจากการทำนายของโมเดลเป็น "ผลลัพธ์" (payout) ของเกม โดย Shapley value จะเป็นค่าที่ระบุว่าควรแบ่งผลลัพธ์ของเกมให้แก่ผู้เล่นแต่ละคนอย่างไรให้เกิดความยุติธรรม โดยพิจารณาจากสัดส่วนการมีส่วนร่วม (contribution) ของผู้เล่นแต่ละคน SHAP ใช้เพื่ออธิบายว่าแต่ละตัวแปร (feature) มีผลต่อการทำนายของโมเดลอย่างไร โดยผลลัพธ์ที่ได้คือค่าตัวเลข Shapley Values ซึ่งบ่งบอกว่าตัวแปรใดส่งผลต่อการทำนาย ยิ่งค่า Shapley Values สูง ยิ่งแสดงว่าตัวแปรนั้นมีอิทธิพลต่อผลลัพธ์มาก ทำให้เราสามารถตีความการตัดสินใจของโมเดลได้ แสดงดังภาพที่ 2.1



ภาพที่ 2.1 ตัวอย่างผลการอธิบายการทำนายด้วย SHAP

การวิเคราะห์ด้วย SHAP สามารถวิเคราะห์ได้ทั้ง ระดับภาพรวม (Global Explanation) และ ระดับเฉพาะกรณี (Local Explanation)

2) Lime (Local Interpretable Model-agnostic Explanations)

เป็นเทคนิคที่ช่วยอธิบายผลกระทบของฟีเจอร์ต่อการทำนายของโมเดล โดยเฉพาะในกรณีที่โมเดลมีความซับซ้อนจนไม่สามารถเข้าใจการทำงานได้โดยตรง (black box) หลักการของ LIME คือการสร้างโมเดลตัวแทนแบบง่าย (Local Surrogate) ที่เลียนแบบพฤติกรรมของโมเดลเดิมในบริเวณข้อมูลที่เราสนใจศึกษา วิธีการทำงานเริ่มจากการสร้างข้อมูลใหม่ที่เปลี่ยนแปลงเล็กน้อยจากข้อมูลต้นฉบับ (perturbed samples) แล้วใช้ข้อมูลเหล่านี้กับโมเดลเดิมเพื่อดูผลลัพธ์ จากนั้นเลือกโมเดลง่าย ๆ เช่น decision tree มาฝึกฝนโดยใช้ข้อมูลชุดนี้ พร้อมทั้งให้น้ำหนักความสำคัญกับข้อมูลแต่ละจุดตามความใกล้เคียงกับข้อมูลที่น่าสนใจ ผลลัพธ์ที่ได้คือโมเดลตัวแทนที่ช่วยอธิบายว่าฟีเจอร์ใดส่งผลกระทบต่อการทำนายในบริเวณข้อมูลนั้นได้อย่างแม่นยำ (local fidelity) เทคนิคนี้จึงช่วยให้ผู้ใช้งานเข้าใจพฤติกรรมของโมเดล AI ได้ชัดเจนขึ้นในระดับข้อมูลรายจุด แม้ว่าโมเดลเดิมจะมีความซับซ้อนเพียงใดก็ตาม แสดงดังภาพที่ 2.2



ภาพที่ 2.2 ตัวอย่างผลการอธิบายการทำนายด้วย LIME

การวิเคราะห์ด้วย LIME สามารถวิเคราะห์ได้เพียง ระดับเฉพาะกรณี (Local Explanation)

3) Anchor เป็นเทคนิคที่ช่วยอธิบายคำทำนายของโมเดล AI โดยใช้กฎ "ถ้า-แล้ว" (if-then)

ที่เรียบง่าย ซึ่งกำหนดว่าเหตุใดคำทำนายถึงเกิดขึ้น เทคนิคนี้สร้างกฎที่เรียกว่า "Anchors" ซึ่งบอกว่าหากเงื่อนไขในกฎนั้นเป็นจริง คำทำนายของโมเดลจะยังคงเหมือนเดิม ไม่ว่าจะมีการเปลี่ยนแปลงฟีเจอร์อื่น ๆ ในข้อมูลอย่างไร กระบวนการทำงานของ Anchor เริ่มจากการทดลองสร้างกฎหลาย ๆ แบบ คัดเลือกกฎที่เหมาะสมที่สุดโดยใช้การเรียนรู้แบบเสริมกำลัง (reinforcement learning) และปรับปรุงกฎนั้นให้ครอบคลุมข้อมูลได้มากที่สุด คำอธิบายที่ได้จะมีความแม่นยำสูงและเข้าใจง่าย เพราะบอกได้ชัดเจนว่าในพื้นที่ข้อมูลที่ Anchor กำหนดไว้ คำทำนายจะไม่มีเปลี่ยนแปลง เทคนิค

นี้ช่วยให้เราเข้าใจโมเดลตัดสินใจอย่างไรในบริเวณข้อมูลที่สนใจ และสามารถสร้างคำอธิบายที่ใช้งานได้หลากหลายและโปร่งใสมากขึ้น แสดงดังภาพที่ 2.3

	If	Predict
adult	No capital gain or loss, never married	$\leq 50K$
	Country is US, married, work hours > 45	$> 50K$
rcdv	No priors, no prison violations and crime not against property	Not rearrested
	Male, black, 1 to 5 priors, not married, and crime not against property	Re-arrested
lending	FICO score ≤ 649	Bad Loan
	$649 \leq \text{FICO score} \leq 699$ and $\$5,400 \leq \text{loan amount} \leq \$10,000$	Good Loan

ภาพที่ 2.3 ตัวอย่างผลการอธิบายการทำนายด้วย Anchor

การวิเคราะห์ด้วย Anchor สามารถวิเคราะห์ได้เพียงระดับเฉพาะกรณี (Local Explanation)

2.2 งานวิจัยที่เกี่ยวข้อง

2.2.1 Explainable AI for malnutrition risk prediction from m-Health and clinical data [6]

งานวิจัยนี้นำเสนองานปัญญาประดิษฐ์ที่สามารถอธิบายได้ (Explainable AI) สำหรับการพยากรณ์ความเสี่ยงจากภาวะทุพโภชนาการในผู้สูงอายุที่อยู่ในสถานดูแล โดยใช้ข้อมูลสุขภาพจากมือถือและข้อมูลทางคลินิก ข้อจำกัดของงานวิจัยนี้คือใช้เฉพาะข้อมูลจากกลุ่มผู้สูงอายุในสถานดูแลระยะยาว ซึ่งทำให้การนำผลไปใช้กับกลุ่มผู้ใช้งานอื่น ๆ เช่น เด็กเล็ก หรือประชากรทั่วไป อาจไม่สามารถทำได้โดยตรง

2.2.2 Determination of Relevant Feature Combinations For Detection Stunting Status of Toddlers [5]

งานวิจัยนี้มุ่งเน้นไปที่การตรวจสอบหาสถานะการแคระแกร็นในเด็กเล็ก โดยใช้วิธีการเรียนรู้ของเครื่องเพื่อระบุคุณสมบัติที่สำคัญจากข้อมูลสุขภาพ งานวิจัยได้ใช้ Support Vector Machine (SVM)

และการเลือกคุณสมบัติที่เกี่ยวข้องเพื่อพัฒนาระบบที่มีความแม่นยำสูงในการตรวจหาสถานะการแคระแกร็น ข้อจำกัดของงานวิจัยนี้คือ ใช้ข้อมูลจากกลุ่มตัวอย่างในพื้นที่จำกัด โดยเฉพาะจากศูนย์สุขภาพหลายแห่งในเมืองสุราบายา ประเทศอินโดนีเซีย ทำให้ผลการวิจัยอาจไม่ครอบคลุมถึงสถานการณ์การแคระแกร็นในเด็กจากพื้นที่อื่น ๆ

2.2.3 Prediction of mortality in severe acute malnutrition in hospitalized children by faecal volatile organic compound analysis: proof of concept [12]

งานวิจัยนี้ศึกษาเกี่ยวกับการใช้สารระเหยอินทรีย์จากอุจจาระ (VOC) เพื่อทำนายการเสียชีวิตในเด็กที่มีภาวะทุพโภชนาการเฉียบพลันรุนแรง (SAM) โดยใช้การวิเคราะห์โปรไฟล์ VOC และอัลกอริทึมการเรียนรู้ของเครื่อง งานวิจัยพบว่ามี ความแตกต่างในโปรไฟล์ VOC ระหว่างเด็กที่รอดชีวิต และเด็กที่เสียชีวิต ซึ่งแสดงให้เห็นถึงศักยภาพในการใช้ VOC เป็นเครื่องมือในการทำนายการเสียชีวิตได้อย่างแม่นยำและไม่รุกราน ข้อจำกัดของงานวิจัยนี้คือ งานวิจัยนี้เน้นที่การวิเคราะห์ข้อมูล VOC โดยไม่ได้รวมข้อมูลด้านอื่น ๆ เช่น ข้อมูลทางโภชนาการ หรือปัจจัยอื่น ๆ ที่อาจส่งผลต่อการเสียชีวิตของเด็ก

ตารางที่ 2.2 การเปรียบเทียบงานวิจัยที่เกี่ยวข้อง

ลำดับ	Feature	โปรเจกต์ที่นำเสนอ	[6]	[5]	[12]
1	เว็บแอปพลิเคชันในการประเมินผล	✓	X	X	X
2	สามารถดูผลลัพธ์การประเมิน	✓	✓	X	X
3	สามารถประเมินความเสี่ยงเบื้องต้นได้	✓	✓	X	X
4	สามารถดูผลการประเมินแบบเรียลไทม์	✓	X	X	X
5	แสดงคำแนะนำในการบริโภคอาหาร	✓	✓	✓	✓
6	Prediction algorithm	LR	RF, GB	NB, KNN, SVM	SVM, LR
7	Explanation algorithm	Shap	Shap	X	X

* LR = Logistic Regression, RF = Random Forest, GB = Gradient Boosting, NB = Naïve Bayes,
KNN = K-Nearest Neighbor, SVM = Support Vector Machine

บทที่ 3

เอกสารความต้องการของระบบ

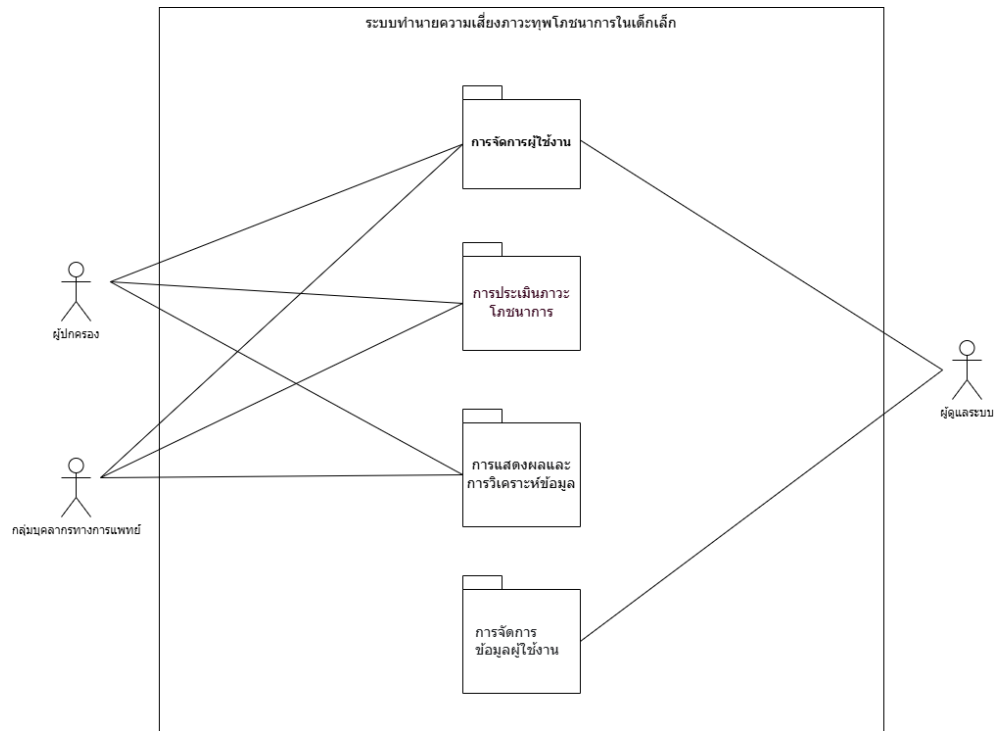
โครงการนี้มุ่งเน้นการพัฒนาโมเดลการเรียนรู้เชิงอธิบาย (Explainable AI) สำหรับประเมินและทำนายความเสี่ยงของภาวะทุพโภชนาการในระยะเริ่มต้น โดยใช้เทคโนโลยีการเรียนรู้ของเครื่อง (Machine Learning) ร่วมกับการพัฒนาเว็บแอปพลิเคชันต้นแบบ เพื่อให้ผู้ใช้งานสามารถติดตามและวิเคราะห์ข้อมูลได้อย่างสะดวกและแม่นยำ ระบบดังกล่าวจะช่วยสนับสนุนการตัดสินใจเชิงการแพทย์ และเพิ่มประสิทธิภาพในการดูแลสุขภาพเด็กในระยะยาว

โครงการนี้มีเป้าหมายเพื่อสนับสนุนการให้ผู้ปกครองและบุคลากรทางการแพทย์สามารถประเมินและติดตามความเสี่ยงภาวะทุพโภชนาการในเด็กเล็กในระยะเริ่มต้นได้อย่างแม่นยำและรวดเร็ว ลดภาระงานในการประเมินภาวะโภชนาการ เพิ่มโอกาสในการป้องกันและรักษาภาวะทุพโภชนาการตั้งแต่ระยะเริ่มต้น รวมถึงส่งเสริมการนำเทคโนโลยีปัญญาประดิษฐ์มาใช้ในการด้านสาธารณสุขอย่างมีประสิทธิภาพ

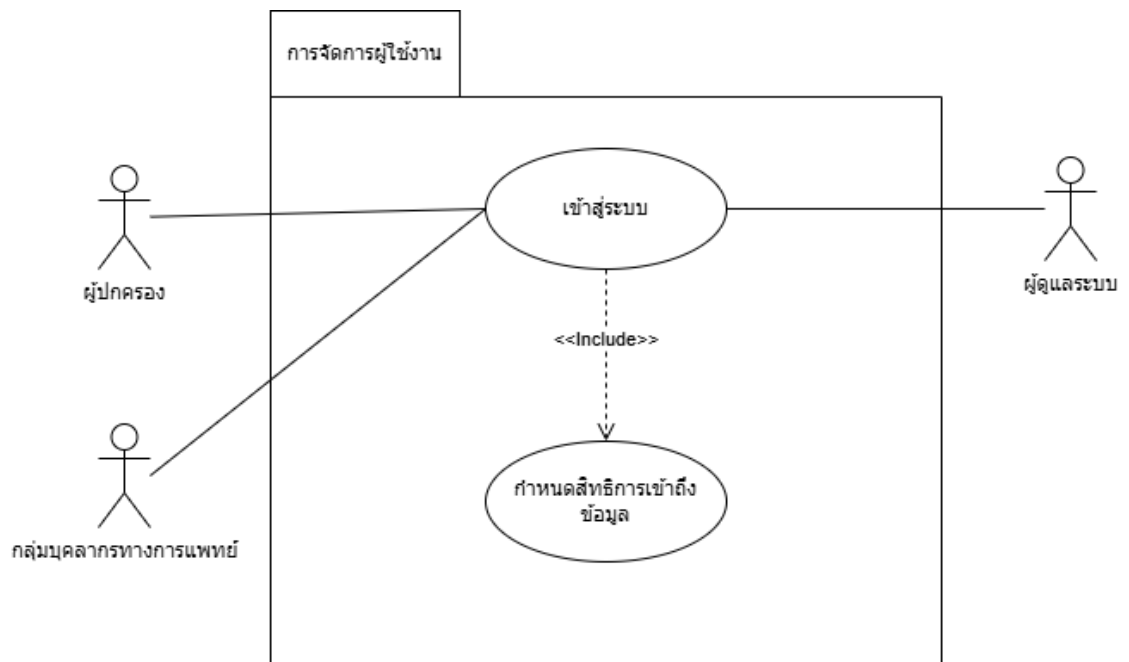
ได้ความต้องการระบบ (Requirement) มาจากโรงพยาบาลทักษิณ จังหวัดสุราษฎร์ธานี

3.1 การวิเคราะห์ระบบ (System Analysis)

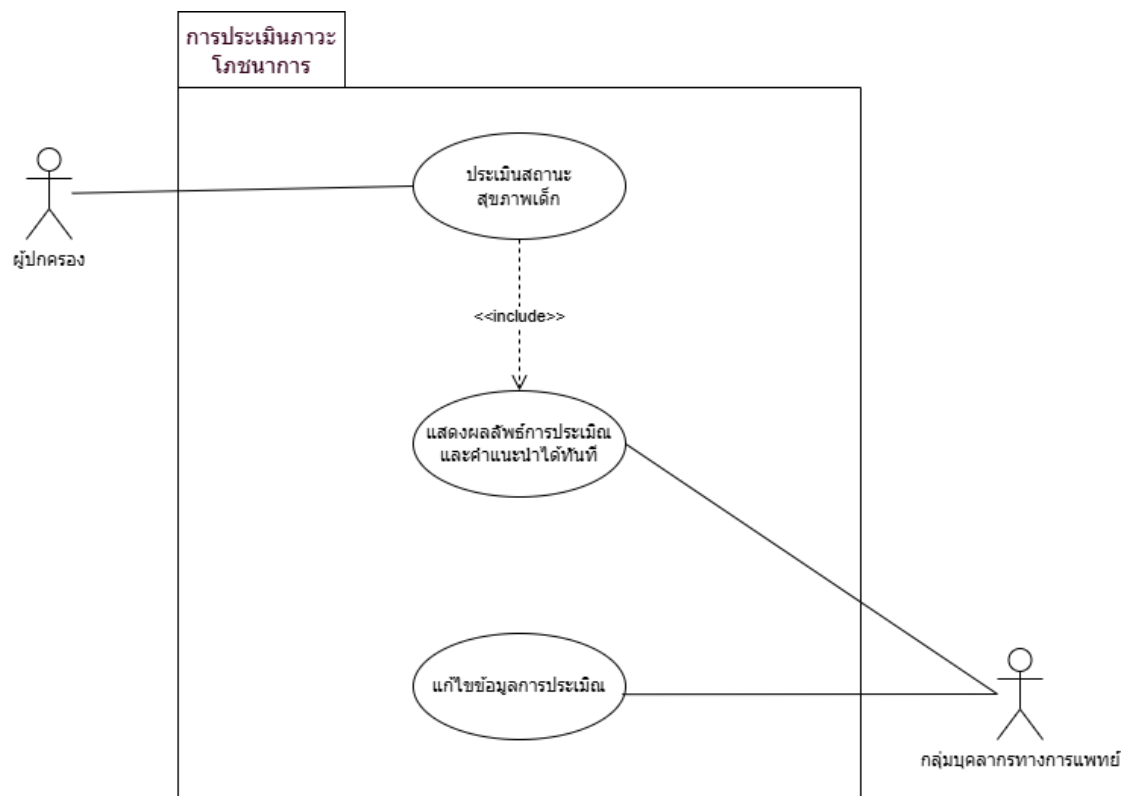
3.1.1 ภาพรวมการใช้งานระบบของผู้ใช้ (Use Case Diagram)



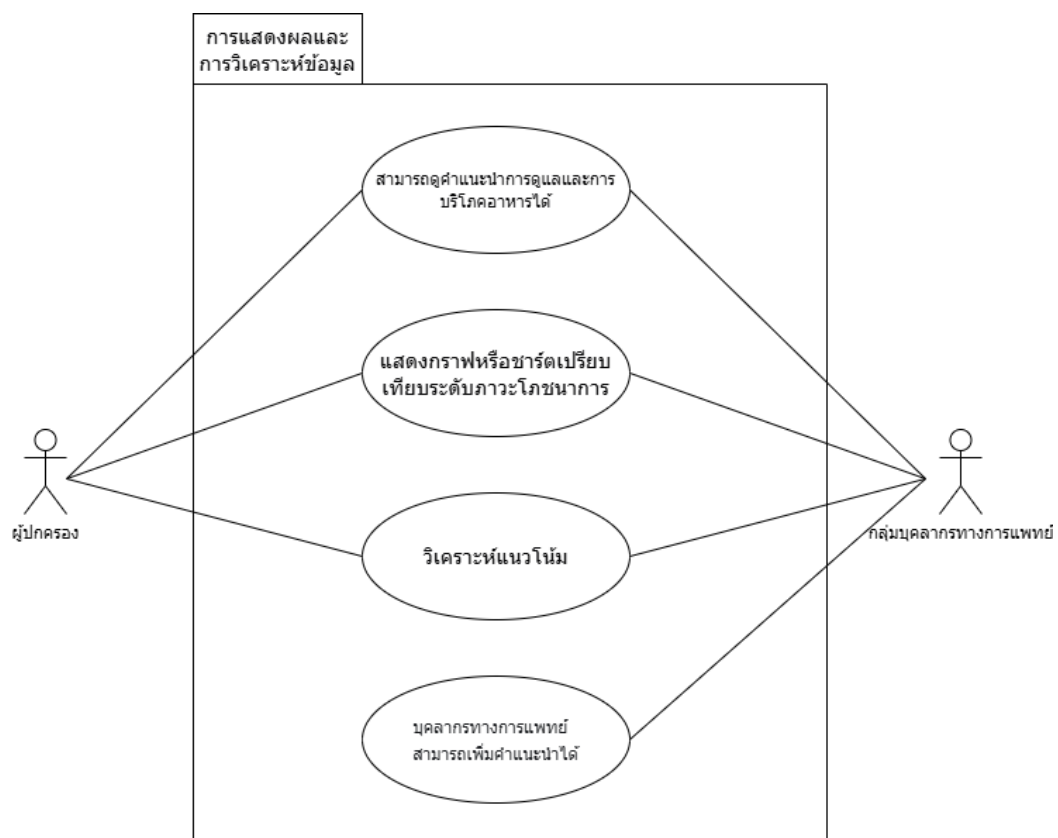
ภาพที่ 3.1 Use Case Diagram ของระบบทั้งหมด



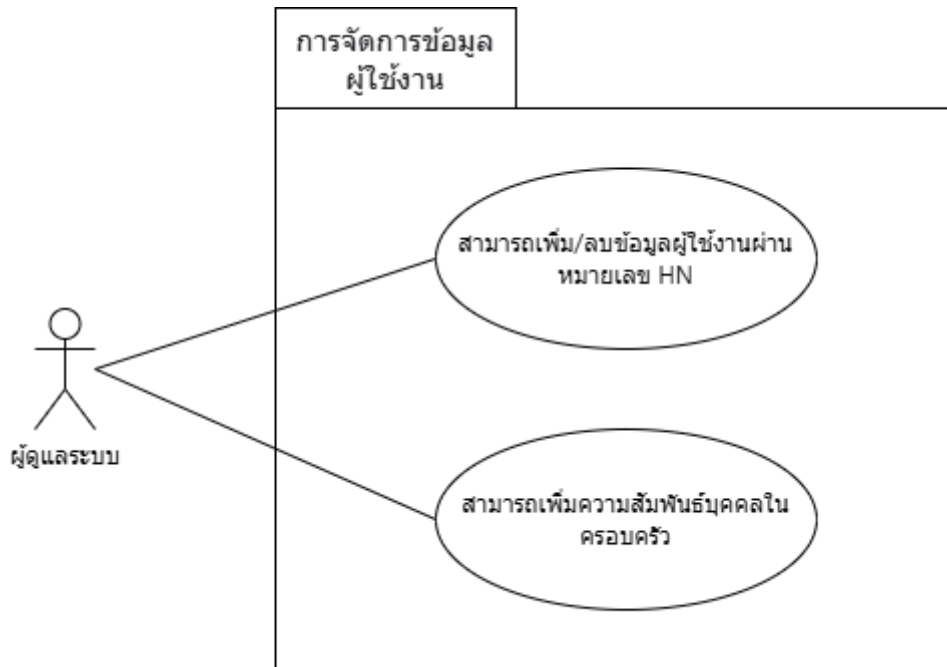
ภาพที่ 3.2 Use Case Diagram ของการจัดการผู้ใช้งาน



ภาพที่ 3.3 Use Case Diagram ของการประเมินภาวะโภชนาการ



ภาพที่ 3.4 Use Case Diagram ของการแสดงผลและการวิเคราะห์ข้อมูล



ภาพที่ 3.5 Use Case Diagram ของการจัดการข้อมูลผู้ใช้งาน

3.1.2 การศึกษาความต้องการของผู้ใช้งาน (User Requirement Analysis)

การเก็บรวบรวมข้อมูลจากกลุ่มผู้ใช้งานเป้าหมายเพื่อวิเคราะห์ความต้องการที่แท้จริงเป็นขั้นตอนสำคัญ ตารางที่ 3.1 คือตารางความต้องการของผู้ใช้ที่ต้องการให้มีการพัฒนา มีรายละเอียดดังต่อไปนี้

ตารางที่ 3.1 ตารางแสดงความต้องการของผู้ใช้

No.	Requirement	Priority
1.	เว็บ Web Application ที่ประกอบไปด้วย 3 Users ได้แก่ ผู้ปกครอง ผู้ดูแลระบบ และ บุคลากรทางการแพทย์	Must have
2.	ผู้ใช้งานสามารถเข้าสู่ระบบผ่านอีเมลและรหัสผ่าน หรือผ่านหมายเลข HN พร้อมรับ OTP ยืนยันตัวตน	Must have
3.	ผู้ปกครองสามารถกรอกข้อมูลน้ำหนัก ส่วนสูง โรคประจำตัว พฤติกรรมการกินอาหาร และการพักผ่อน เพื่อรับผลการประเมินว่า "ปกติ" หรือ "ควรพบแพทย์"	Must have
4.	บุคลากรทางการแพทย์สามารถแก้ไขข้อมูลการวินิจฉัย	Must have

5.	ผู้ใช้งานสามารถดูคำแนะนำในการปรับเปลี่ยนการดูแลและการบริโภคอาหาร	Could have
6.	ผู้ปกครองและบุคลากรทางการแพทย์สามารถดูประวัติการประเมินย้อนหลังได้	Must have
7.	ระบบใช้ SHAP ในการอธิบายฟีเจอร์ที่มีผลต่อการประเมินต่างๆได้	Must have
8.	ผู้ดูแลระบบสามารถเพิ่ม/ลบข้อมูลผู้ใช้งานและจัดการข้อมูลบุคคลในแผนกเด็กผ่านหมายเลข HN	Must have
9.	ระบบต้องแสดงผลลัพธ์การประเมินและคำแนะนำได้ทันทีหลังจากกรอกข้อมูล	Must have
10.	UX/UI ใช้งานง่าย รองรับผู้ใช้งานทุกกลุ่ม	Should have
11.	ต้องมีค่าความแม่นยำไม่ต่ำกว่า 85% และมีการประเมินประสิทธิภาพของโมเดลอย่างต่อเนื่อง	Must have
12.	ระบบต้องกำหนดระดับสิทธิ์ เช่น ผู้ปกครองเข้าถึงข้อมูลเฉพาะของลูกตัวเอง ส่วนบุคลากรทางการแพทย์สามารถเข้าถึงข้อมูลทั้งหมด	Must have
13.	ระบบต้องสามารถวิเคราะห์แนวโน้มว่าดีขึ้นหรือแย่ลงหลังจากผ่านการเข้ารับการรักษาจากแพทย์ เช่น การเปลี่ยนแปลงค่า BMI หรือพฤติกรรมการบริโภคอาหารของเด็กในช่วงเวลาต่าง ๆ	Must have
14.	ระบบแสดงผลข้อมูล เช่น ค่า BMI หรือการเปรียบเทียบระดับภาวะโภชนาการ ผ่านกราฟหรือชาร์ตที่เข้าใจง่าย	Must have
15.	ผู้ดูแลระบบสามารถเพิ่มความสัมพันธ์บุคคลในครอบครัวได้	Must have
16.	บุคลากรทางการแพทย์สามารถเพิ่มคำแนะนำได้	Should have

เมื่อได้ทำการรวบรวมและเรียงลำดับความสำคัญของความต้องการจากผู้ใช้งานเสร็จสิ้นแล้ว ขั้นตอนถัดไปคือการตรวจสอบและวิเคราะห์เพื่อระบุฟังก์ชันที่เหมาะสมในการตอบสนองความต้องการเหล่านั้น โดยเน้นพิจารณาว่าฟังก์ชันใดสามารถแก้ไขปัญหาได้อย่างมีประสิทธิภาพ พร้อมทั้งเชื่อมโยงฟังก์ชันที่ออกแบบให้ตรงกับความต้องการแต่ละข้ออย่างชัดเจน เพื่อรับรองว่าฟังก์ชันดังกล่าวตอบสนองต่อความต้องการของผู้ใช้ได้อย่างครบถ้วนและตรวจสอบได้

ตารางที่ 3.2 ตารางแสดงคุณลักษณะของ UC-01: การจัดการผู้ใช้งาน (User Management)

คุณลักษณะ: UC-01: การจัดการผู้ใช้งาน (User Management)

คำอธิบาย: ระบบรองรับการใช้งานของผู้ใช้งานประเภทต่าง ๆ ได้แก่ ผู้ปกครอง ผู้ดูแลระบบ และบุคลากรทางการแพทย์ โดยมีการจัดการระดับสิทธิ์การเข้าถึงข้อมูล		
Actor: ผู้ปกครอง ผู้ดูแลระบบ บุคลากรทางการแพทย์		
เงื่อนไข (ถ้ามี): <ol style="list-style-type: none"> ผู้ใช้งานต้องสามารถเข้าสู่ระบบผ่านอีเมลและรหัสผ่าน หรือผ่านหมายเลข HN พร้อม OTP ระบบต้องรองรับระดับสิทธิ์การเข้าถึงข้อมูล 		
หมายเลข	คำอธิบายข้อกำหนดความต้องการ	ความสำคัญ (M,S,C,W)
Req 1	ระบบรองรับการใช้งานผ่าน Web Application	M
Req 2	ผู้ใช้งานสามารถเข้าสู่ระบบด้วยการยืนยันตัวตน	M
Req 12	ระบบกำหนดระดับสิทธิ์ เช่น ผู้ปกครองเข้าถึงข้อมูลเฉพาะของลูกตัวเอง	M

ตารางที่ 3.3 ตารางแสดงคุณลักษณะของ UC-02: การประเมินภาวะโภชนาการ (Nutrition Assessment)

คุณลักษณะ: การประเมินภาวะโภชนาการ (Nutrition Assessment)		
คำอธิบาย: ระบบสามารถประเมินภาวะโภชนาการได้จากข้อมูลที่กรอกโดยผู้ใช้งาน และแสดงผล		
Actor: ผู้ปกครอง บุคลากรทางการแพทย์		
เงื่อนไข (ถ้ามี): <ol style="list-style-type: none"> ข้อมูลที่ใช้ประกอบการประเมิน ได้แก่ น้ำหนัก ส่วนสูง โรคประจำตัว พฤติกรรมการกินอาหาร ระบบต้องรองรับการประเมินแบบเรียลไทม์ 		
หมายเลข	คำอธิบายข้อกำหนดความต้องการ	ความสำคัญ (M,S,C,W)
Req 3	ผู้ปกครองสามารถกรอกข้อมูลน้ำหนัก ส่วนสูง โรคประจำตัว พฤติกรรมการกินอาหาร และการพักผ่อน เพื่อรับผลการประเมินว่า "ปกติ" หรือ "ควรพบแพทย์"	M

Req 4	บุคลากรทางการแพทย์สามารถแก้ไขข้อมูลการวินิจฉัย	M
Req 9	ระบบแสดงผลผลการประเมินและคำแนะนำได้ทันทีหลังจากกรอกข้อมูล	M

ตารางที่ 3.4 ตารางแสดงคุณลักษณะของ UC-03: การแสดงผลและการวิเคราะห์ข้อมูล (Visualization and Analysis)

คุณลักษณะ: UC-03: การแสดงผลและการวิเคราะห์ข้อมูล (Visualization and Analysis)		
คำอธิบาย: ระบบแสดงผลผลการประเมินและการวิเคราะห์แนวโน้มในรูปแบบที่เข้าใจง่าย		
Actor: ผู้ปกครอง บุคลากรทางการแพทย์		
เงื่อนไข (ถ้ามี): <ol style="list-style-type: none"> ระบบต้องแสดงข้อมูลแบบกราฟิก เช่น กราฟเปรียบเทียบค่า BMI ระบบต้องสามารถวิเคราะห์แนวโน้มของข้อมูลย้อนหลังได้ 		
หมายเลข	คำอธิบายข้อกำหนดความต้องการ	ความสำคัญ (M,S,C,W)
Req 5	ผู้ใช้งานสามารถดูคำแนะนำในการปรับเปลี่ยนการดูแลและการบริโภคอาหาร	C
Req 6	ผู้ปกครองและบุคลากรทางการแพทย์ดูประวัติการประเมินย้อนหลังได้	M
Req 10	UX/UI ใช้งานง่าย รองรับผู้ใช้งานทุกกลุ่ม	S
Req 13	ระบบวิเคราะห์แนวโน้ม เช่น การเปลี่ยนแปลงค่า BMI	M
Req 14	ระบบแสดงกราฟหรือชาร์ตเปรียบเทียบระดับภาวะโภชนาการ	M
Req 16	บุคลากรทางการแพทย์สามารถเพิ่มคำแนะนำได้	S

ตารางที่ 3.5 ตารางแสดงคุณลักษณะของ UC-04: การจัดการข้อมูลผู้ใช้งาน (User Data Management)

คุณลักษณะ : UC-04: การจัดการข้อมูลผู้ใช้งาน (User Data Management)
คำอธิบาย: ระบบรองรับการเพิ่ม ลบ และจัดการข้อมูลผู้ใช้งาน

Actor: ผู้ดูแลระบบ		
เงื่อนไข (ถ้ามี):		
<ol style="list-style-type: none"> 1. ผู้ดูแลระบบต้องสามารถเพิ่ม/ลบข้อมูลผู้ใช้งานได้ 2. ผู้ดูแลระบบสามารถเพิ่มความสัมพันธ์บุคคลในครอบครัวได้ 		
หมายเลข	คำอธิบายข้อกำหนดความต้องการ	ความสำคัญ (M,S,C,W)
Req 8	ผู้ดูแลระบบสามารถเพิ่ม/ลบข้อมูลผู้ใช้งานผ่านหมายเลข HN	M
Req 15	ผู้ดูแลระบบสามารถเพิ่มความสัมพันธ์บุคคลในครอบครัวได้	M

3.1.2 การวิเคราะห์ระบบปัจจุบัน (Existing System Analysis)

ปัจจุบัน การประเมินความเสี่ยงจากภาวะทุพโภชนาการในเด็กยังคงใช้แบบประเมินดั้งเดิมที่ออกแบบตามกลุ่มประชากรเฉพาะ และต้องพึ่งพาบุคลากรทางการแพทย์ แพทย์ในการวินิจฉัยและประเมินผล ซึ่งมักมีข้อจำกัดด้านทรัพยากรและเวลา รวมถึงภาระงานที่สูงจากการขาดแคลนบุคลากรทางการแพทย์ ส่งผลให้ไม่สามารถเข้าถึงข้อมูลและวิเคราะห์ความเสี่ยงได้อย่างรวดเร็วหรือครอบคลุม

ในงานวิจัยที่ผ่านมา เช่น การใช้ Support Vector Machine (SVM) เพื่อทำนายภาวะกระดูกพรุนในเด็กในพื้นที่จำกัด พบว่าแม้ผลลัพธ์จะมีความแม่นยำ (Accuracy 84.16%) แต่ยังขาดการวิเคราะห์เชิงลึกเพื่อหาสาเหตุและเสนอแนวทางแก้ไข

อีกตัวอย่างหนึ่ง คือ การใช้ Explainable AI (XAI) ในการวิเคราะห์ภาวะทุพโภชนาการของผู้สูงอายุในศูนย์ดูแล พบว่าระบบสามารถอธิบายผลลัพธ์ได้ชัดเจน แต่ข้อมูลที่ใช้งานยังคงเฉพาะกลุ่มและไม่สามารถนำไปประยุกต์ใช้ในกลุ่มเด็กได้โดยตรง

3.1.3 การระบุปัญหาและโอกาสพัฒนา (Problem and Opportunity Identification)

ในปัจจุบัน การประเมินภาวะโภชนาการในเด็กยังคงใช้วิธีการที่ล้าสมัย เช่น การประเมินด้วยแบบฟอร์มดั้งเดิมที่ต้องใช้ผู้เชี่ยวชาญวินิจฉัย ส่งผลให้เกิดข้อจำกัดในด้านทรัพยากร เช่น การขาดแคลนบุคลากรทางการแพทย์ และเวลาที่ใช้ในการวิเคราะห์ข้อมูล รวมถึงข้อมูลจากการประเมินยังไม่ได้รับการประมวลผลเชิงลึกเพื่อสนับสนุนการตัดสินใจอย่างมีประสิทธิภาพ

โอกาสในการพัฒนา

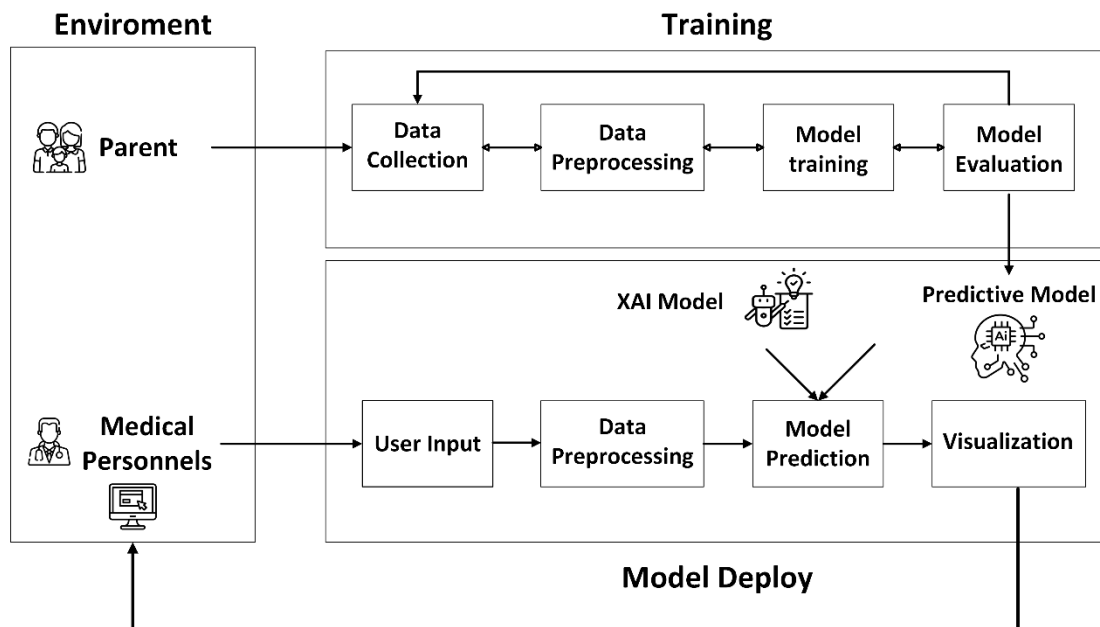
1. **การใช้ Explainable AI (XAI):** การนำ XAI มาช่วยในการประมวลผลข้อมูลทางสุขภาพ ช่วยเพิ่มความแม่นยำในการวิเคราะห์ความเสี่ยงจากปัจจัยต่าง ๆ และสามารถอธิบายผลลัพธ์ได้อย่างชัดเจนเพื่อสนับสนุนบุคลากรทางการแพทย์
2. **การพัฒนา Web Application:** การใช้งาน Web Application ช่วยให้ผู้ป่วยและบุคลากรทางการแพทย์สามารถเข้าถึงข้อมูลการประเมินภาวะโภชนาการได้แบบเรียลไทม์ และสะดวกต่อการใช้งานประหยัดเวลาในการวิเคราะห์หรือประมวลผลการรักษาต่างๆ

บทที่ 4

การออกแบบระบบ

จากเทคโนโลยีที่นำมาใช้ในโครงการนี้ได้มีการออกแบบระบบเพื่อการศึกษาและพัฒนาโครงการ โดยข้อมูลดิบได้มาจากแหล่งข้อมูลที่อยู่ในรูปแบบการเผยแพร่ผ่านเว็บไซต์เพื่อนำมาใช้ในการพัฒนาตัวแบบการเรียนรู้และระบบต้นแบบ ซึ่งมีรายละเอียดดังนี้

4.1 สถาปัตยกรรมซอฟต์แวร์ของระบบ



ภาพที่ 4.1 กรอบแนวคิดระบบต้นแบบทำนายความเสี่ยงภาวะทุพโภชนาการในเด็กเล็ก โดยใช้เทคโนโลยีระบบปัญญาประดิษฐ์เชิงอธิบาย

จากภาพที่ 4.1 ซึ่งเป็นกรอบแนวคิดของการออกแบบระบบโดยรวม แบ่งออกเป็น 2 ส่วนหลักคือ **Environment** เป็นข้อมูลที่ได้มาจากการซักประวัติสุขภาพของเด็กที่มาจากผู้ปกครอง ข้อมูลทางการแพทย์ที่มาจากบุคลากรทางการแพทย์ และ **Computing** เป็นส่วนที่ใช้ในการประมวลผลต่างๆ เมื่อได้รับข้อมูลที่ส่งมาจาก **Environment**

ภายใน **Computing** จะแบ่งออกเป็นอีก 2 ส่วนย่อยคือ ส่วนที่เป็นระยะการเทรนโมเดลซึ่งประกอบด้วย **Data collection** หรือการเก็บข้อมูลแล้วส่งต่อไปยัง **Data Preprocessing** หรือการเตรียมข้อมูล เสร็จแล้วจึงส่งต่อไปที่ **Model Prediction** เพื่อพัฒนาโมเดล จากนั้นจึงนำโมเดลที่ได้

ไปทดสอบที่ Model Evaluation จนกระทั่งได้โมเดลที่มีประสิทธิภาพตามต้องการจึงนำส่งโมเดลนั้นไปใช้งาน โดยใน ระยะเวลาเทรนโมเดลนี้ กระบวนการต่าง ๆ จะถูกเชื่อมต่อกันด้วยลูกศร 2 ด้านและเส้นประซึ่งหมายความว่า อาจมีการย้อนกลับไปทำกระบวนการก่อนหน้า เช่น การเก็บข้อมูลใหม่ การเตรียมข้อมูลใหม่

อีกส่วนหนึ่งของ Computing คือระยะการใช้งานระบบจริงซึ่งประกอบด้วย Data sensing หรือ การเก็บข้อมูลแล้วส่งข้อมูลที่ได้นำมาเข้ากระบวนการ Data Preprocessing เพื่อจัดการเตรียมการข้อมูล ให้พร้อมในการเข้าสู่โมเดล Model Prediction คือกระบวนการทำนายผลที่ได้เรียนรู้จากข้อมูลนำเข้าเพื่อ นำผลลัพธ์ส่งกลับไปยัง Environment ในการแสดงผลผ่าน Web Application


รายละเอียดของแต่ละกระบวนการ ได้แก่

4.1 Training

4.1.1 กระบวนการรวบรวมข้อมูล (Data Collection)

คือการนำเข้าข้อมูลดิบผ่านการเก็บรวบรวมผ่านเว็บไซต์ โดยข้อมูลที่ได้เป็นข้อมูลดิบ (Raw Data) คือไม่ผ่านกระบวนการจัดการข้อมูลใด โดยมีแหล่งที่มา คือมาจากองค์กร Global Nutrition Report ซึ่งเป็นองค์กรสำรวจข้อมูลล่าสุดเกี่ยวกับโภชนาการในระดับโลก ระดับภูมิภาค และระดับประเทศ ด้วยแผนภูมิแบบโต้ตอบที่ให้คุณเห็นความคืบหน้าของประเทศของคุณต่อการบรรลุเป้าหมายด้านโภชนาการระดับโลก มีการรวบรวมข้อมูลจำพวกการบริโภคอาหารของเด็ก สารอาหารที่ต้องการและสารอาหารที่ได้รับ ร้อยละของประชากรที่ใช้แหล่งน้ำดื่มแต่ละแห่ง ครอบคลุม 186 ประเทศทั่วโลก มีข้อมูลครอบคลุมปี 2000-2020 ซึ่งมีความน่าเชื่อถือและสอดคล้องต่อการวิเคราะห์ภาวะทุพโภชนาการของมนุษย์ ตัวอย่างข้อมูลแสดงดังภาพที่ 4.2

Source of drinking water



SOURCES AND NOTES

ภาพที่ 4.2 ตัวอย่างข้อมูลเผยแพร่จาก Global Nutrition Report

โครงการนี้จึงใช้วิธีการทำ web crawler ในการสกัดและรวบรวมข้อมูลมาให้อยู่ในโครงสร้างข้อมูลแบบตาราง โดยข้อมูลแบ่งเป็น 5 หมวด ได้แก่ ข้อมูลส่วนตัว, ข้อมูลประเทศ, แหล่งน้ำดื่ม, การบริโภคอาหารตามหมวดหมู่ และสุขาภิบาล


โดยผลลัพธ์ที่ได้มีจำนวน 837 แถว 29 คอลัมน์ ตัวอย่างข้อมูลแสดงดัง ตารางที่ 4.1

ตารางที่ 4.1 ข้อมูลก่อน Preprocessing ตัวอย่าง

No.	Variables	Definition	Type	State	Missing Value
1.	Dietary_intakes_National	การบริโภคอาหารของประชากรในระดับประเทศ ซึ่งเป็นข้อมูลเกี่ยวกับพฤติกรรมการกินอาหารของประชากรในแต่ละประเทศ โดยเน้นปริมาณและชนิดของอาหารที่บริโภคในแต่ละวันหรือช่วงเวลาที่กำหนด เพื่อประเมินสถานะโภชนาการ สุขภาพ และแนวโน้มพฤติกรรมการบริโภคอาหารในระดับประชากร	Categorical	Red meat (63.68%), Fish (28.20%), Dairy (2.27%), Whole grains (2.67%),	11
2.	Dietary_intakes_Fruit(G)	การบริโภคผลไม้ในอาหารประจำวันหน่วยเป็นกรัม	Numerical	3.9-499.9(μ 92.781719 \pm 51.627187)	11

4.1.2 การเตรียมข้อมูล (Data Preprocessing)

จากการเก็บข้อมูลผ่านการเก็บรวบรวมผ่านเว็บไซต์ ข้อมูลที่ได้อาจมีทั้งหมดมีจำนวน 837 แถว และ 29 คอลัมน์ โดยข้อมูลที่ได้มีค่าว่างทั้งหมด 9 คอลัมน์ คือ Dietary_intakes_National, Dietary_intakes_Fruit(G), Dietary_intakes_Vegetables(G), Dietary_intakes_Legumes(G), Dietary_intakes_Nuts(G), Dietary_intakes_Whole_grains(G), Dietary_intakes_Fish(G), Dietary_intakes_Dairy(G), Dietary_intakes_Red_meat(G) และมีการสร้างคอลัมน์ใหม่ (Feature Engineering) คือ คอลัมน์ Status_Personal โดยการสร้าง Feature Status_Personal โดยขั้นตอนการเตรียมข้อมูล เป็นดังภาพที่ 4.3



ภาพที่ 4.3 แผนภาพแสดงขั้นตอนการเตรียมข้อมูล

จากภาพที่ 4.3 เป็นการแสดงขั้นตอนการประมวลผลข้อมูลโดยมี ขั้นตอนดังนี้

1. **Missing Data** หรือการเติมข้อมูลที่ขาดหาย จะเป็นการเติมข้อมูลทั้ง 9 คอลัมน์ที่ขาดหาย โดยใช้การเติมข้อมูลด้วยค่าเฉลี่ย ที่เปรียบเทียบจากประเทศภูมิภาคเดียวกันและมีรายได้เหมือนกัน
2. **Feature Engineering** เป็นการเพิ่ม feature ใหม่เข้ามานั้นคือ status_personal เพื่อที่จะทราบว่าจากน้ำหนักส่วนสูงของข้อมูลที่มีของคนๆนั้นมีโอกาสที่จะเป็นภาวะทุพโภชนาการอะไร โดยจะนำค่าน้ำหนักส่วนสูงไปคำนวณหาค่าน้ำหนักต่อส่วนสูง (Weight-for-length/height) และนำค่าน้ำหนักต่อส่วนสูงนั้นมาใช้เพื่อวิเคราะห์ว่ามีโอกาสเป็นภาวะทุพโภชนาการอะไร

ผลลัพธ์ที่ได้จากการทำ Preprocessing แสดงตัวอย่างดังที่ตารางที่ 4.2

ตารางที่ 4.2 ข้อมูลหลัง Preprocessing ตัวอย่าง

No.	Variables	Definition	Type	State	Missing Value
1.	Dietary_intakes_National	การบริโภคอาหารของประชากรในระดับประเทศ ซึ่งเป็นข้อมูลเกี่ยวกับพฤติกรรมการกินอาหารของประชากรในแต่ละประเทศ โดยเน้นปริมาณและชนิดของอาหารที่บริโภคในแต่ละวันหรือช่วงเวลาที่กำหนด เพื่อประเมินสถานะโภชนาการ สุขภาพ และแนวโน้มพฤติกรรมการบริโภคอาหารในระดับประชากร	Categorical	Red meat (63.68%), Fish (28.20%), Dairy (2.27%), Whole grains (2.67%),	0
2.	Dietary_intakes_Fruit(G)	การบริโภคผลไม้ในอาหารประจำวันหน่วยเป็นกรัม	Numerical	3.9-499.9(μ 92.781719 \pm 51.627187)	0

4.1.3 การพัฒนาตัวแบบการเรียนรู้ (Model Training)

คือ การนำข้อมูลที่ผ่านมากระบวนการประมวลผลข้อมูลเรียบร้อยแล้วจากขั้นตอน Data Preprocessing ข้อมูลที่ได้จะเป็นลักษณะไฟล์ DataFrame (.csv) และมีผล Label ออกเป็น 6 กลุ่ม ข้อมูล คือ ภาวะปกติ ภาวะน้ำหนักเกิน ภาวะอ้วน ภาวะน้ำหนักน้อยเกินไป แคระแกร็น และภาวะทุพโภชนาการเฉียบพลันรุนแรง (SAM)

เนื่องจากข้อมูลของโครงการนี้เป็นการ classification หรือการแยกกลุ่มของข้อมูล จากข้อมูลที่โมเดลได้เรียนรู้เพื่อให้ได้ผลลัพธ์ตามผลการทำนาย อัลกอริธึมของการ classification ที่เป็นไปได้ในการเรียนรู้ข้อมูลของโครงการนี้ ได้แก่

- 1) Artificial Neural Network-based algorithm: Multi-layer Perceptron
- 2) Distance-based algorithm: KNeighbors, C-Support Vector
- 3) Logical-based algorithm: Decision Tree, Random Forest, Extra-Trees
- 4) Probabilistic-based algorithm: Gaussian Naive Bayes, Logistic Regression
- 5) Ensemble algorithm: Gradient Boosting, AdaBoost, XGBoost

การนำอัลกอริธึมมาใช้กับข้อมูลจะต้องทำการ เปรียบเทียบ Algorithm ที่เป็นไปได้ทั้งหมดและเลือกอัลกอริธึมที่ดีที่สุดในการพัฒนาตัวแบบการเรียนรู้ ซึ่งอัลกอริธึมดังกล่าวจะมีการพัฒนาตัวแบบการเรียนรู้ด้วยการทำ Hyperparameter Optimization คือ GridSearchCV โดยมี Search Space ของแต่ละอัลกอริธึม ดังตารางที่ 4.3

ตารางที่ 4.3 Hyperparameter Optimization Search Space

Algorithm	Search Space
MLPClassifier	hidden_layer_sizes: [50 , 100, 200 , 300], activation: ["relu", "tanh", "logistic", "identity"], solver: ["adam", "sgd", "lbfgs"], alpha: [0.0001, 0.001], learning_rate: ["constant", "invscaling", "adaptive"]
KNClassifier	n_neighbors: [3, 5, 7], weights: ["uniform", "distance"],

	metric: ["euclidean", "manhattan"], leaf_size: [30, 50], p: [1, 2]
SVC	C: [1, 10, 100], kernel: ["rbf", "poly", "sigmoid", "linear"], gamma: ["scale", "auto"], cache_size: [200, 400], class_weight: ["balanced"], decision_function_shape: ["ovo", "ovr"]
DTClassifier	criterion: ["gini", "entropy", "log_loss"], max_depth: [5, 10, <i>None</i>], min_samples_split: [2, 5, 10], min_samples_leaf: [1, 2, 4], max_features: ["sqrt", "log2", <i>None</i>], class_weight: ["balanced"]
RandomForestClassifier	n_estimators: [50, 100, 200], criterion: ["gini", "entropy", "log_loss"], max_depth: [5, 10, <i>None</i>], min_samples_split: [2, 5, 10], min_samples_leaf: [1, 2, 4], max_features: ["sqrt", "log2", <i>None</i>], class_weight: ["balanced"]
ExtraTreesClassifier	n_estimators: [50, 100, 200], criterion: ["gini", "entropy", "log_loss"], max_features: ["sqrt", "log2"], max_depth: [5, 10, <i>None</i>], min_samples_split: [2, 5, 10], min_samples_leaf: [1, 2, 4], max_features: ["sqrt", "log2", <i>None</i>], class_weight: ["balanced"]
GaussianNB	var_smoothing: [1e-9, 1e-8, 1e-7]

LogisticRegression	C: [0.01, 0.1, 1, 10], solver: ["lbfgs", "newton-cg", "sag", "saga"], class_weight: ["balanced"], multi_class: ["multinomial"], penalty: ["l2", "l1", "none", "elasticnet"], max_iter: [100, 200, 300], l1_ratio: [0.1, 0.5, 0.9, <i>None</i>]
GradientBoostingClassifier	n_estimators: [100, 200, 300], learning_rate: [0.1, 0.01, 0.001], max_depth: [3, 5, 10], loss: ["log_loss", "exponential"], criterion: ["friedman_mse", "squared_error"], subsample: [0.8, 1.0], min_samples_split: [2, 5, 10], min_samples_leaf: [1, 2, 4], max_features: ["sqrt", "log2", <i>None</i>],
AdaBoostClassifier	"estimator": [DecisionTreeClassifier(max_depth=1), RandomForestClassifier(max_depth=1), ExtraTreesClassifier(max_depth=1), LogisticRegression()], n_estimators: [50, 100, 200], learning_rate: [0.01, 0.1, 1]
XGBClassifier	objective: ["multi:softprob", "multi:softmax"], learning_rate: [0.1, 0.2, 0.3], max_depth: [1, 3, 5], n_estimators: [200, 300], subsample: [0.1, 0.5, 0.9], colsample_bytree: [0.1, 0.5, 0.9], model__gamma: [0.1, 0.5, 0.9],

4.1.4 การประเมินผลตัวแบบการเรียนรู้ (Model Evaluation)

คือการประเมินประสิทธิภาพของอัลกอริทึมที่เปรียบเทียบกับแต่ละตัวกับข้อมูลชุดเดียวกัน แล้วจะเลือกมาอัลกอริทึมเดียวที่มีผลดีที่สุดและมีประสิทธิภาพสูงที่สุด โดยใช้ Accuracy, Precision และ Recall ในการประเมินผลของ แล้วนำอัลกอริทึมนั้นไปใช้เป็นตัวแบบการทำนายที่จะให้ XAI มาอธิบายผลการทำนายอีกครั้ง

4.2 Model Deploy

4.2.1 ผู้ใช้ป้อนข้อมูล (User Input)

คือข้อมูลที่ผู้ใช้งาน เช่น พ่อแม่หรือบุคลากรทางการแพทย์ ป้อนเข้าสู่ระบบเพื่อให้โมเดลทำการวิเคราะห์และประมวลผลข้อมูลที่ป้อนเข้ามานี้เป็นข้อมูลที่ได้อาจมาจากกรอกของผู้ใช้งาน สามารถป้อนข้อมูลนี้ผ่านช่องทางเว็บแอปพลิเคชัน ระบบจะนำข้อมูลเหล่านี้ไปประมวลผลเพื่อวิเคราะห์ภาวะสุขภาพและการ และหากตรวจพบความเสี่ยง ระบบจะให้คำแนะนำเพื่อเข้าพบแพทย์ในขั้นตอนต่อไป

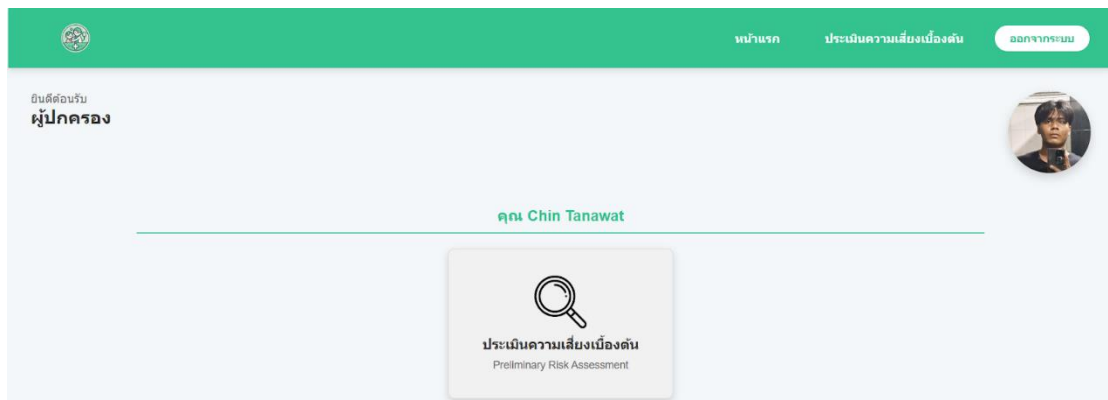
4.2.2 การเตรียมข้อมูล (Data Preprocessing)

ในกระบวนการนำข้อมูลใหม่ที่ได้รับจาก User Input มาประมวลผล จำเป็นต้องมีการเตรียมข้อมูลให้เหมือนกับขั้นตอนที่ใช้ในระหว่างการเรียนรู้โมเดล เพื่อให้โมเดลสามารถทำงานได้อย่างถูกต้องและความแม่นยำสูงสุด นอกจากนี้ ยังต้องทำการแปลงข้อมูลให้อยู่ในรูปแบบที่เหมาะสม เช่น การปรับสเกลข้อมูล (Normalization หรือ Standardization) เพื่อให้ข้อมูลที่มีหน่วยหรือช่วงค่าต่างกันอยู่ในขอบเขตเดียวกัน รวมถึงการ Encoding สำหรับข้อมูลที่เป็นประเภทข้อความ หรือหมวดหมู่ เช่น การแปลง "เด็กชาย" และ "เด็กหญิง" เป็นตัวเลข เช่น 0 และ 1 ขั้นตอนนี้เป็นอีกขั้นตอนสำคัญที่จะช่วยให้แบบจำลองสามารถประมวลผลข้อมูลใหม่ได้อย่างต่อเนื่องและมีประสิทธิภาพ การรักษาความสม่ำเสมอระหว่างขั้นตอนการ Training และ Deployment

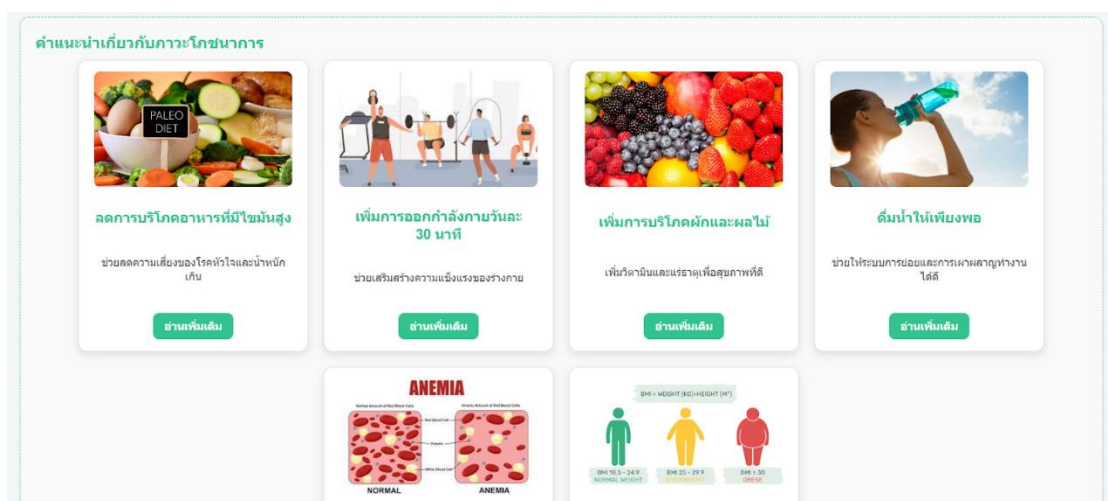
4.2.3 การแสดงผล (Visualization)

จากการฝึกฝนอัลกอริทึมในการเรียนรู้และทำนาย ผลการทำนายที่ได้จะแสดงผลในรูปแบบของ Web Application เพื่อใช้ในการสนับสนุนบุคลากรทางการแพทย์ในการประเมินภาวะสุขภาพของเด็กได้อย่างแม่นยำและรวดเร็ว

1. ภาพรวมการทำงานของระบบ (System Overview)



ภาพที่ 4.4 รูปแบบหน้าจอ Web Application ของผู้ปกครอง



ภาพที่ 4.5 รูปแบบหน้าจอ Web Application ของผู้ปกครอง

ประเมินความเสี่ยงเบื้องต้น

อายุ:

น้ำหนัก:

ส่วนสูง:

เพศ:

โรคประจำตัว:

มื้ออาหารต่อวัน:

บันทึกและประเมิน

ย้อนกลับ

ผลการประเมิน

กรุณารอกข้อมูลและกดปุ่มประเมิน

ภาพที่ 4.6 รูปแบบหน้าจอประเมินความเสี่ยงเบื้องต้น ของผู้ปกครอง

ยินดีต้อนรับ

บุคลากรทางการแพทย์

หน้าแรก

ออกจากระบบ

น.พ. ณัฏฐพล ทองอนันต์

ดูผลลัพธ์การประเมินของผู้ป่วย

วันที่: 01/02/2025
ประเภทการรักษာ:
จากล่าสุด

ชื่อผู้ป่วย	วันที่	เวลา	สถานะ	รายละเอียด
ศุภณัฐ ญะวงษ์	30/11/2567	10:30:00	หมอ เฝื่อนมากกว่าปกติ	<button>กดเพื่อดู</button>
พศณณิศา บริติธิประภา	29/11/2567	14:20:00	น้ำหนักปกติ	<button>กดเพื่อดู</button>
ศุภณัฐ ญะวงษ์	25/11/2567	08:15:00	หมอมาก	<button>กดเพื่อดู</button>

ภาพที่ 4.7 รูปแบบหน้าจอ Web Application ของบุคลากรทางการแพทย์

ผลลัพธ์การประเมินของผู้ป่วย



ศวิญญ์ หนองศ์

HN: 1

อายุ: 11

เพศ: หญิง

น้ำหนัก: กก.

ส่วนสูง: ซม.

ความดันโลหิต:

โรคประจำตัว: ไม่มี

ภูมิแพ้: ไม่มี

ประวัติทางการแพทย์:

แก้ไขข้อมูลการซักประวัติ

ดูประวัติย้อนหลังผู้ป่วย

BMI = 10.03

อยู่ในเกณฑ์: ผอม เสี่ยงมากกว่าปกติ

ภาพที่ 4.8 รูปแบบหน้าจอการดูผลลัพธ์การประเมิน ของบุคลากรทางการแพทย์

กราฟ:



กราฟนี้แสดงถึงปัจจัยที่ส่งผลต่อภาวะทุพโภชนาการ:

สีแดง: ชี้ให้เห็นถึงการบริโภคเกินมาตรฐาน


สีน้ำเงิน: ชี้ให้เห็นถึงการขาดสมดุลของการบริโภค

หมายเหตุ:

- +0.92 (สีแดง): การบริโภคไขมันที่สูงกว่าปกติ
- 0.52 (สีน้ำเงิน): การขาดสารอาหารประเภทโปรตีนและไฟเบอร์

ภาพที่ 4.9 รูปแบบหน้าจอการดูผลลัพธ์การประเมิน ของบุคลากรทางการแพทย์

กราฟพัฒนาการ:



กราฟนี้แสดงพัฒนาการด้านน้ำหนักและส่วนสูง:

สีเขียวเข้ม: แสดงน้ำหนักปกติ

สีส้ม: น้ำหนักต่ำกว่าเกณฑ์

หมายเหตุ:

- การเจริญเติบโตอยู่ในระดับต่ำกว่าปกติ ต้องเสริมสารอาหารประเภทโปรตีน
- น้ำหนักของผู้ป่วยยังอยู่ในเกณฑ์ต่ำกว่าเกณฑ์เมื่อเปรียบเทียบกับอายุ

ภาพที่ 4.10 รูปแบบหน้าจอการดูผลลัพธ์การประเมิน ของบุคลากรทางการแพทย์

ผลการตรวจ:

Test	Results	Reference Interval	LOW	NORMAL	HIGH
BMI	10.03	15.05	<div></div>		
ปริมาณรับประทานอาหาร		3 ครั้ง / วัน		<div></div>	
การนอนหลับ		9-11 ชม. / วัน	<div></div>		
การขับถ่าย		1-2 ครั้ง / วัน		<div></div>	

คำแนะนำ:

- เพิ่มโปรตีน
- เน้นการรับประทานไขมันดี

คำแนะนำจากแพทย์:

คำแนะนำที่บันทึก:

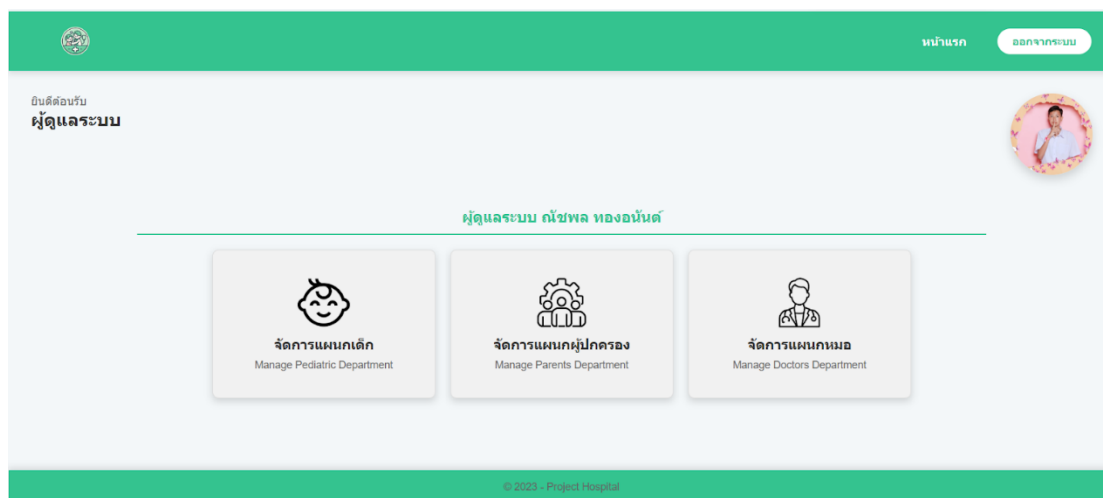
ยังไม่มีคำแนะนำที่บันทึก

กรอกคำแนะนำสำหรับผู้ป่วย

บันทึก

ย้อนกลับ

ภาพที่ 4.11 รูปแบบหน้าจอการดูผลลัพธ์การประเมิน ของบุคลากรทางการแพทย์



ภาพที่ 4.12 รูปแบบหน้าจอ Web Application ของผู้ดูแลระบบ

บรรณานุกรม

- UNICEF (2024). Child Food Poverty: A report on children's malnutrition and food Insecurity. [Online]. Available: <https://www.unicef.org/reports/child-food-poverty>
- มหาวิทยาลัยราชภัฏสวนสุนันทา (2562). การศึกษาการเกิดภาวะทุพโภชนาการในเด็ก. [Online]. Available: <http://hs.ssru.ac.th/useruploads/files/20190306/2c390014e73fe56f827a4dd38db6896a24756008.pdf>
- Cederholm, T., Jensen, G., Correia, M., Gonzalez, M. C., Fukushima, R., Higashiguchi, T., et al. (2019). GLIM criteria for the diagnosis of malnutrition – A consensus report from the global clinical nutrition community. *Journal of Cachexia, Sarcopenia and Muscle*, 10(1), 207–217.
- สมาคมโภชนาการแห่งประเทศไทย. คู่มือประเมินติดตามภาวะโภชนาการและพัฒนารเด็กปฐมวัย. [Online]. Available: <https://www.thaidietetics.org/wp-content/uploads/2023/04/17825569354720-คู่มือประเมินติดตามภาวะโภชนาการฯ-ข.pdf>
- Hakimah, M., Prabiantissa, C. N., Rozi, N. F., Yamani, L. N., & Puspitasari, I. (2022, December). Determination of Relevant Feature Combinations For Detection Stunting Status of Toddlers. In 2022 5th International Seminar on Research of Information Technology and Intelligent Systems (ISRITI) (pp. 324-329). IEEE.
- Di Martino, F., Delmastro, F., & Dolciotti, C. (2023). Explainable AI for malnutrition risk prediction from m-health and clinical data. *Smart Health*, 30, 100429.
- กระทรวงสาธารณสุข (2565). ปัจจัยที่มีผลต่อภาวะโภชนาการเด็กปฐมวัยไทยในเขตสุขภาพที่ 6. [Online]. Available: hpc6.anamai.moph.go.th/th/cms-of-15/download/?did=219288&id=102864&reload=
- Indiran Govender, Selvandran Rangiah, Ramprakash Kaswa, Doudou Nzaumvila (2024). Malnutrition in children under the age of 5 years in a primary health care setting. [Online]. Available: Malnutrition in children under the age of 5 years in a primary health care setting - PMC

Mike McNamara. Explainable AI: What is it? How does it work? And what role does data play? [Online]. Available: Explainable AI: What is it? How does it work? And what role does data play? (netapp.com)

Scott Lundberg. SHAP documentation. [Online]. Available: Welcome to the SHAP documentation — SHAP latest documentation

GeeksforGeeks. Explainable AI(XAI) Using LIME. [Online]. Available: Explainable AI(XAI) Using LIME - GeeksforGeeks

Deborah A. van den Brink, Tim de Meij, Daniela Brals, Robert H. J. Bandsma, Johnstone Thitiri, Moses Ngari, Laura Mwalekwa, Nanne K. H. de Boer, Alfian Wicaksono, James A. Covington, Patrick F. van Rheenen & Wieger P. Voskuil. (2020). Prediction of mortality in severe acute malnutrition in hospitalized children by faecal volatile organic compound analysis: proof of concept. Scientific Reports volume 10, Article number: 18785